基于概念层次的语句概念结构语料库标注规范（草案）

1 范围

本规范（草案）提出了汉语语料库语句概念结构标注符号及代码的内容。

本规范（草案）可供汉语语料库语句概念结构标注及以此为基础的中文信息处理参考。

2 术语和定义

2.1 语言空间

各种自然语言本身，如汉语、英语等。

2.2 语言概念空间

根据概念层次网络理论制定的、适用于各种语言的概念符号体系，是对语言空间内容的再抽象。包括四个层级：语言概念基元符号体系，也称为概念基元空间；句类符号体系，也称句类空间；语境单元符号体系，也称语境单元空间；语境符号体系，也称语境空间。

2.3 作用效应链

反映事物存在发展变化的最大共性，由作用、过程、转移、效应、关系、状态等六个环节组成，是语言概念空间（2.2）中概念基元空间的核心、句类空间的基本构件和语境空间的结构主体。

2.4 句类

根据语句中主要概念团块间的联想脉络进行分类而形成的语句类型体系，即语句的概念联想类型。

2.5 基本句类

仅突出体现作用效应链（2.3）中某个特定环节的句类。根据作用效应链的内容，基本句类划分为57组。

2.6 混合句类

作用效应链（2.3）两个或两个以上基本句类的特征体现在一个句子中时所对应的句类。这种混合往往是基本句类的两两混合，常用的混合句类在理论上有57×56=3192组。

2.7 语义块

构成句子的下一级成分，句子中的概念团块，句子内概念联想脉络的承载单位；其形式上可以是一个词、一个短语或者一个句子。

2.8 主语义块

体现语句中主要概念联想脉络关系的语义块，可简称主块。根据其描述的是表达对象还是表达对象的表现，又可以分成特征语义块和广义对象语义块两大类。广义对象语义块又可进一步分成作用者、对象和内容三种基元，分别用A、B、C代表。

2.9 辅语义块

弱依赖于语句概念联想脉络的语义块，包括方式、工具、途径、参照、条件、动因和目的等语义块，可简称辅块。

2.10 句蜕

语义块的一种构成方式，语句或语句的变形嵌入到语义块中，充当整个语义块或者语义块的一部分，此时句蜕语句的主语义块仍然服从其所属句类的约束。

2.11 原型句蜕

句蜕的一种表现形式，由语句直接充当语义块或其中的一部分。

2.12 要素句蜕

句蜕的一种表现形式，语句经过变形后充当语义块或其中的一部分。注：汉语的表现形式通常是将表述中心放到后边，在表述中心前加“的”，然后在“的”前边给出蜕化句子的剩余部分。

2.13 包装句蜕

句蜕的一种表现形式，在原型或要素句蜕的基础上增加相关词语，对句蜕内容进行概括或指定。

2.14 块扩

某些句类的特定主语义块由语句充当的情况。

2.15 共享句

多个语句整体共享某个主语义块。

2.16 部分共享句

多个语句共享某个主语义块的一部分。

2.17 迭句

共享句的一种，后一语句共享前一语句的第一个广义对象语义块。

2.18 链句

共享句的一种，后一语句的第一个广义对象语义块共享前一个语句的最后一个广义对象语义块。

2.19 列句

在一个标注单元内，不存在共用语义块的多个语句。

2.20 语句概念结构

语句中各成分之间的概念联想结构以及它们的排列形式，在本规范中用句类表示式、语句格式和语句间共享语义块的形式加以表述，并体现为语句句式（语句之间的各种共享和非共享句）、语句格式代码和句类代码。

3 语料标注符号

3.1 语言空间的标注符号

语料语言空间的标注符号，见表1、表2。

表1 独立出现的语言空间标注符号

序号	符号	说明
1	+ +	列句之间的间隔符号
2	+	迭句之间的间隔符号
3	+ ~	链句之间的间隔符号
4	+ *	除迭句和链句之外的其他共享句之间的间隔符号
5	%	部分共享句的说明符号
6	| |	语句级语义块间隔符号
7	~	辅语义块的说明符号
8	|	句蜕中语义块的间隔符号
9	&	并合内容的说明符号

表2中的符号由左右两部分组成，成对出现，标明标注内容的类型和边界。

表 2　配对出现的语言空间标注符号

序号	符号	说明
1	{ }	原型句蜕的标记间隔符号
2	< >	要素句蜕的标记间隔符号
3	\ /	包装句蜕的标记间隔符号
4	[##]	块扩语句的标记间隔符号
5	[ ]	词语优先组合标记间隔符号
6	[- -]	特征语义块向前分离成分的标记间隔符号
7	[+ +]	特征语义块向后分离成分的标记间隔符号
8	[| |]	广义对象语义块向前分离成分的标记间隔符号
9	[= =]	广义对象语义块向后分离成分的标记间隔符号

3.2　语言概念空间的标注符号

语料语言概念空间的标注符号，见表3。

表 3　语言概念空间的标注符号

序号	符号	说明
1	+ +	列句句类代码之间的间隔符号
2	+	迭句句类代码之间的间隔符号
3	+ ~	链句句类代码之间的间隔符号
4	+ *	除迭句和链句之外的其他共享句句类代码之间的间隔符号
5	%	部分共享句句类代码的说明符号
6	&	辅块插入的标记符号
7	EJ	基本句类句类代码表示的语句概念结构 E 是抽象表示，标注时具体的句类代码按附录 A《基本句类名称、代码及语义块表示式》给出

续表

序号	符号	说明
8	E1E2*kmnJ	混合句类句类代码表示的语句概念结构类型。E1 和 E2 的含义和取值同上面的 E，kmn 表示混合句类广义对象语义块的情况。其中，k 表示广义对象语义块的总数，m 表示从 E1 句类中第一个广义对象语义块依次选取广义对象语义块的个数，n 表示从 E2 句类中依次选取广义对象语义块的起始位置，选取 k－m 个广义对象语义块。如果不从 E2 中选取广义对象语义块，或者 n＝m＋1 时，n 应省略。
9	! km	以语句格式代码表示的主语义块顺序。标注时，按附录 B《语句格式代码设计说明》给出具体的语句格式代码。
10	#	句蜕的标记符号表示多级句蜕时需连写
11	=%	语义块部分构成中包含句蜕的标记符号
12	[ ]	优先组合标记符号
13	{ }	原型句蜕标记符号
14	< >	要素句蜕标记符号
15	\ /	包装句蜕标记符号
16	[# #]	块扩标记符号

4 语料标注及示例

4.1 概述

语句概念结构语料标注，以一个句号、问号或叹号等句末点号点断的内容为标注单元。在语料文本上进行语言空间的标注，给出各种切分的类型与切分点；另起一行，进行语言概念空间标注，给出语言概念空间的各种结构信息。

本规范（草案）使用的各种标注符号均为半角西文符号。

4.2 语料的语言空间标注

4.2.1 语言空间标注符号的使用

在本规范（草案）中，语言空间标注符号的左右侧要有空格，凸显标注符号。

当标注符号连用时，之间只保留一个空格。当标注符号出现在句首或者句尾时，相应左侧或右侧的空格应当省略。说明符和间隔符连用时，中间不用空格而直接组合。

4.2.2 语句间的标注

根据语句之间主语义块共享情况，选用相应的语句间隔符号进行标注。

如果语句之间有标点符号，语句间隔符号应当标注在标点符号的右侧。

如果语句共享的不是整个主语义块，需要使用部分共享句说明符号。根据主语义块共享的情况，将“%”添加在“+”“+~”“+*”后，分别表示：

+%：语句间只共享第一个广义对象语义块的一部分。

+~%：后面语句的第一个广义对象语义块部分共享前面语句最后一个广义对象语义块。

+*%：除上述两种情况之外的主语义块部分共享。

示例1：

〈孙中山先生|领导|的辛亥革命〉||，推翻了||〈统治|中国|[+几千年+]的君主专制制度〉，+对{中国社会|进步}~||具有||重大意义，+但也未能改变||中国[半殖民地&半封建的社会性质]和&[人民的悲惨命运]。

注：迭句。有三个语句，它们共用了第一个语句的“孙中山先生领导的辛亥革命”充当第一个广义对象语义块。

示例2：

美||将首设||[[对华]办]+~监督||{中国|是否遵守|国际贸易条款}

注：链句。有两个语句，第二个语句以前一个语句的第二广义对象语义块“对华办”作为它的第一个广义对象语义块。

示例3：

这方面的经验教训||，我们||已经进行了系统的总结，+*大家||必须牢牢记取。

注：一般共享句。有两个语句，第一个语句的第二广义对象语义块“……教训”提前，并用逗号点断，第二个语句也以此作为第二个广义对象语义块。

示例4：

〈[|那个|]挖|阴沟|的人〉||仪表非凡：+%身材||修长、清瘦——+堪称||优雅，+%绝对不像||一个典型的工人。

注：有两个部分共享句。第一句和第二句之间部分共享“……人”，第二句的“身材”是指“……人”的身材。第二句和第三句是迭句，共享第一个广义对象语义块。第三句和第四句之间部分共享，第三句的第一个广义对象语义块是“那个人的身材”，第四句的第一个广义对象语义块是“那个人”。

示例5：

美国民航业||过去曾经是||一个高度垄断的行业，+ +政府||对市场准入||实行||严格限制。

注：有两个语句。第一句和第二句不共享广义对象语义块，列句。

4.2.3 语义块间的标注

在本规范（草案）中区分语句级语义块和句蜕嵌套语句语义块，使用不同的语义块间隔符号。对于句蜕中再嵌套的句蜕，在间隔符号上不再区分。

语句级主语义块之间使用语句语义块间隔符号，句蜕嵌套语句中的主语义块使用句蜕中语义块的间隔符号。切分辅语义块时，需要在辅语义块出现的一侧添加辅语义块说明符。

如果语义块之间有标点符号，语义块间隔符号应当标注在标点符号的左侧。

块扩部分的语句属于语句一级，不属于句蜕级。因此块扩内语义块之间的间隔符号使用语句级语义块间隔符号。

如果块扩的边界上有标点符号，则块扩的左侧标记在标点符号的右侧，右侧标记在标点符号的左侧。

示例：

有关专家||分析||,[#从短期看~||,全球石油产量和需求量||仍大体平衡#]。

注：这个语句“？分析”之后的部分是块扩。块扩部分内有辅语义块。

4.2.4　句蜕的标注

根据句蜕的类型选择相应的句蜕符号对句蜕进行标注。

在包装句蜕中需要标明其中的原型或要素句蜕。

如果句蜕的边界上有标点符号，则句蜕的左侧标记在标点符号的右侧，右侧标记在标点符号的左侧。

注：参阅4.2.2的示例1、2和4。

4.2.5　词语优先组合

将需要优先组合的词语用词语优先组合标记间隔符号标注出来，表示它们优先组合。词语优先组合标记间隔符号通常与并合内容的间隔符号（&）一起出现，标明语义块内部词语之间的结构关系。

对于上述两种情况，如果其边界上有标点符号，则左侧标记在标点符号的右侧，右侧标记在标点符号的左侧。

注：参阅4.2.2的示例1和2。

4.2.6　主语义块分离现象的标注

如果主语义块发生分离，需要标注出主语义块中分离出去的部分。在标注时需要区分特征语义块和广义对象语义块的分离，以及分离出去的部分是向前（左）还是向后（右）分离。对具体的情况，采用相应的符号进行标注。

如果主语义块分离部分的边界有标点符号，则分离标注的左侧标记应在标点符号的右侧，右侧标记应在标点符号的左侧。注：参阅4.2.2的示例1和4。在示例1中，句蜕部分的“几千年”应当和“统治”一起构成特征语义块，但是这里出现了特征语义块分离现象，“几千年”分离到了“统治”之后。示例4中是句蜕块的广义对象语义块分离，“那个”应和“人”在一起构成“挖”的第一个广义对象语义块。

4.3　语料的语言概念空间标注

语言概念空间标注的内容包括两个层面：语句和句蜕。其共同核心是用句类代码方式表述的语句概念结构。

4.3.1　语句的标注

首先根据语句的概念联想脉络确定语句的句类代码。其次，根据语句语义块

具体出现的顺序确定语句格式代码。这样就完成了对语句概念结构的描述。然后，根据语言空间标注的语句间隔符号选择相应的语言概念空间间隔符号，在间隔符号的右侧给出下一个语句的概念结构描述。

如果语句中有辅块，则在对应语句概念结构描述的左侧给出辅块的具体名称；如果辅块与语句之间有逗号点断，则用“&”连接。

如果语句中有块扩，则从左向右依次对每一个块扩语义块进行描述。描述的方法是：在对应语句概念结构描述右侧用“［#GBK#］”（其中 GBK 是具体块扩语义块的代码）标记块扩的语义块，后接等号，在等号的右侧给出块扩部分的语句概念结构描述；同样的方式描述下一个块扩语句。

示例 1：

〈孙中山先生|领导|的辛亥革命〉||，推翻了||〈统治|中国|[+几千年+]的君主专制制度〉，+对{中国社会|进步}～||具有||重大意义，+但也未能改变||中国[半殖民地 & 半封建的社会性质]和 &[人民的悲惨命运]。

R011X*22J#RB1 =〈R411J〉#RB2 =〈!242R411X*21J〉+ ReCS0jD1*20J#ReC = {PS*10J} + XY0*22J

示例 2：

美||将首设||[[对华]办]+～监督||{中国|是否遵守|国际贸易条款}

XY10*211J + ～T19X*21J#B = {XS*22J}

示例 3：

这方面的经验教训||，我们||已经进行了系统的总结，+*大家||必须牢牢记取。

!212D01Ya0*21J +*!212X20Y80*21J

示例 4：

〈[|那个|]挖|阴沟|的人〉||仪表非凡：+%身材||修长、清瘦——+堪称||优雅，+%绝对不像||一个典型的工人。

S04J#SB =〈!242XJ〉+%S041J + D2J +%jD00J

示例5：

美国民航业||过去曾经是||一个高度垄断的行业，+ +政府||对市场准入||实行||严格限制。
jDJ + + !1111XX4*311J

示例6：

有关专家||分析||，[#从短期看~||，全球石油产量和需求量||仍大体平衡#]。
DJ[#DBC#] = [ReR7J]

4.3.2 句蜕的标注

如果标注的语句中有句蜕，则在语句概念结构描述的后面以#引导句蜕表示。在#之后，给出句蜕语义块的具体代码，然后用等号“=”间隔。在等号的右侧给出句蜕部分的语句概念结构描述，并用与语言空间标注对应的句蜕间隔符号说明句蜕的类型。

如果句蜕中出现嵌套，形成多级句蜕，对于嵌套中的句蜕则需要使用多个#标明句蜕嵌套的层次，其他标注同上。

如果在标注的语句中存在多个、多级句蜕，则按照从左到右、先高层后低层的顺序依次标注。

如果一个语义块中有多个同级的句蜕语句，则在对应的语义块代码等号的右侧用“[]”标注，将多个句蜕的类型和语句概念结构描述其中。

如果句蜕语句只是语义块的一部分，则用包含句蜕说明符号“=%”替代上述的等号进行表示。

示例：

二十多年来~||，我们||大胆探索，+勇于实践，+不断推进||〈经济体制|改革〉&、〈政治体制|改革〉和&其他方面的改革，+ +极大地[解放和&[发展了]]||我国社会生产力，+推动||{{我国经济|发展}和&{社会|进步}|发生了|巨大变化}。
Cn&T19S*11J + X20S*11J + XY60*21J#YC = % [〈Y5J〉〈Y5J〉] + + ! 31[[X301]

[XY40*21]]J + XY60*21J#Y6C = {Y10J}##Y1B = [{Y4J}{Y5J}]

注：在本句中有两个相同句类（XY60*21J）的语句，分别是第 3 句和第 5 句，它们的 YC 语义块中都出现了句蜕，而且有多个相同级别的句蜕。对于第 3 句，句蜕只是语义块的一部分，因此在标注的时候使用了“=%”表示语义块构成中包括句蜕。对于第 5 句，句蜕中嵌套句蜕，而且有两个第二级句蜕。关于句蜕标注的其他情况还可以参阅 4.3.1 中的示例。

附录 A
（规范性附录）
基本句类代码表

编号	基本句类命名	句类表示式
	作用句	
1	基本作用句	XJ = A + X + B B = XB + YB + YC
	承受句	
4	一般承受句	X10J = X1B + X10 + XBC X100J = X1B + [X10] + XBC [X10] = X10Q + [X10H] X101J = X1B + X10 + XBC X10 = X10Q + X10H X102J = X1B + X10Q + 〈XBC + X10H〉
5	主动承受句	X11J = X1A + X11 + XBC X110J = X1A + [X11] + XBC [X11] = X11Q + [X11H] X111J = X1A + X11 + XBC X11 = X11Q + X11H X112J = X1A + X11Q + 〈XBC + X11H〉
6	被动承受句	X12J = X1B + X12 + XAC
7	特殊承受句	X109J = XBC + X109 + X1B
	反应句	
8	一般反应句	X20J = X2B + X20 + XBC
9	主动反应句	X21J = X2A + X21 + XBC
10	被动反应句	X22J = X2B + X22 + XAC

编号	基本句类命名	句类表示式
11	后继反应句	X200J = X2B + X200 + X2C X2C = (E) + EC
12	作用反应句	X29J = XAC + X29 + X2BC X291J = XAC + X29 + X2B
	免除句	
13	一般免除句	X300J = X3B + X30 + X3C X301J = X3A + X30 + XBC X302J = X3B + X30 + XAC
14	主动免除句	X31J = X3A + X31 + XABC XABC = XAC + XBC
15	被动免除句	X32J = X3B + X32 + XAC
3	约束句	X4J = A + X4 + X4B X4B = XB + YB;X4BB + X4BC X401J = X4 + X4B X4B = X4BB + X4BC% X402J = X4B + X4 X4B = X4BB + X4BC%
2	块扩作用句	X03J = A + X03 + X03BC X03BC = J
	过程句	
41	一般过程句	PmJ = PB + P (m≠0) P 0J = PB + P + PC Pm0J = PB + P + PC (m≠0) P 01J = PBC + P Pm01J = PBC + P (m≠0)
42	基本过程句	PJ = PB + P
43	素描句	P11J = PB + P11 + PC
44	因果果因句	P21J = PBC1 + (P21) + PBC2 P22J = PBC2 + P22 + PBC1
	转移句	

编号	基本句类命名	句类表示式
16	一般转移句	T0J = TA + T0 + TB + TC T00J = TA + T0 + TB + ∑TBn + TC　n = (1,3) T01J = TA + T0 + TC T02J = TA + T0 + TB
34	传输句	T0aJ = TC + T0a + TB2 T0a0J = TC + T0a + ∑TBn　n = (1,2,3) T0a1J = TC + T0a + TB1 T0a3J = TC + T0a + TB3 T2aJ = T2C + T2a + TB2 T2a0J = T2C + T2a + ∑TBn　n = (1,2,3) T2a1J = T2C + T2a + TB1 T2a3J = T2C + T2a + TB3 T3aJ = T2C + T2a + TB2 T3a0J = T2C + T2a + ∑TBn　n = (1,2,3) T3a1J = T2C + T2a + TB1 T3a3J = T2C + T2a + TB3
35	接收句	T1J = TB + T1 + T1C T10J = TB + T1 + ∑TBn + T1C　n = (1,3)
20	针对性接收句	T19J = TA + T19 + TBC T190J = TA + T19 + ∑TBn + TBC n = (1,3)
17	物转移句	T2J = TA + T2 + TB + T2C T20J = TA + T2 + TB + ∑TBn + T2C n = (1,3) T21J = TA + T2 + T2C T22J = TA + T2 + TB
19	自身转移句	T2bJ = TA + T2b + TB2 T2b0J = TA + T2b + TB2 + ∑TBn n = (1,3) T2b1J = TA + T2b + TB1 T2b3J = TA + T2b + TB3

编号	基本句类命名	句类表示式
18	信息转移句	T3J = TA + T3 + TB + T3C T30J = TA + T3 + TB + ∑TBn + T3C n = (1,3) T31J = TA + T3 + T3C T32J = TA + T3 + TB
36	交换句	T49J = T4B + T49 + T4C T4B = T4B1T4B2;T4B1 + T4B2
21	对等交换句	T490J = T4BC1 + T49 + T4BC2 T4BCn = T4Bn + T4Cn　　n = (1,2) T4C1:=〉In
22	控制交换句	T4901J = T4B0 + T49 + T4B1 + T4C T4902J = T4B0 + T49 + T4B2 + T4C
23	先入交换句	T491J = TA + T49 + T4BC1
24	先出交换句	T492J = TA + T49 + T4B2 + T4C
	替代句	
25	基本替代句	T4a1J = T4B1 + T4a + T4BC2
26	扩展替代句	T4a10J = T4B1 + T4a + T4B2 + T4C
27	扩展双向替代句	T4a0J = T4B + T4a + T4C T4B = T4B1T4B2;T4B1 + T4B2
45	双向替代句	T4aJ = T4B + T4a T4B = T4B1T4B2;T4B1 + T4B2
37	变换句	T4bJ = T4BC1 + T4b + T4BC2 T4b1J = T4b + T4b1 T4b10J = *l*02 + T4b1 + T4b T4b2J = T4b + T4b2 T4b20J = *l*02 + T4b2 + T4b
	效应句	
38	一般效应句	Y01J = YBC + Y Ym01J = YBC + Y　(m≠0) YmJ = YB + Y　(m≠0) Y0J = YB + Y + YC Ym0J = YB + Y + YC　(m≠0)
40	基本效应句	YJ = YB + Y

编号	基本句类命名	句类表示式
33	双对象效应句	Y02J = YB1 + Y02 + YB2 Ym 02J = YB1 + Y02 + YB2　m = (7 ~ 9)
	关系句	
38	双向关系句	RmJ = RB + R RB = RB1RB2;RB1 + RB2
30	扩展双向关系句	Rm0J = RB + R + RC RB = RB1RB2;RB1 + RB2
28	基本主从关系句	Rm10J = RB1 + R + RB2 Rm11J = RB1 + R + RB2 Rm12J = RB2 + R + RB1
29	扩展主从关系句	Rm100J = RB1 + R + RB2 + RC Rm110J = RB1 + R + RB2 + RC Rm120J = RB2 + R + RB1 + RC
	状态句	
46	一般状态句	S01J = SBC + S SmJ = SB + S　(m≠0) S0J = SB + S + SC Sm0J = SB + S + SC　(m≠0) Sm01J = SBC + S　(m≠0)
47	基本状态句	SJ = SB + S
48	换位状态句	S02J = SB + S02 + SC SC = K(j01) S03J = SB + S03 + SC SC = K(j01)
57	简明状态句	S04J = SB + SC
	判断句	
31	一般判断句	D0J = DA + D + DB + DC D01J = DA + D + DBC
32	块扩判断句	DJ = DA + D + DBC DBC = J
	基本判断句	
51	是否判断句	jDJ = DB + jD + DC

编号	基本句类命名	句类表示式
52	存在判断句	jD1J = DB + jD1 + DC jD10J = jD1 + DBC
49	相互比较判断句	jD 0 0J = DBC1 + jD0 0 + DB2 = DB1 + jD0 0 + DBC2 jD 0 0 0J = jDBC + jD00 0 jD 0 0 = (*j*lv111) + jD 0 0 + (hJ) hJ:|的 jDBC = DB1DB2 + DC;DBC1 + DB2; DB1 + DBC2;DB1 + DB2
55	集内比较判断句	jD 01J = DB + jDC DB = Cn + DB0 jD 011J = Cn + *j*lv116 + DB + *lj*lv + DB 0 + jDC jD 012J = Cn + *j*lv116 + *lj*lv + DB0 + jDBC
50	标准比较判断句	jD 02J = DBC + jD0 + DB02 jD 020J = DBC + *l*02 + DB02 + jD0
54	参照比较判断句	jD 021J = DB + jDC DB = DB1 + *lj*lv + DB2 jD022J = DB + jDC DB = *l*02 + DB2 + *lj*lv + DB1
53	简明判断句	D1J = DBC + D1 D2J = DB + D2 + DC jD0J = jDBC + jDC jDBC = DB1DB2 + DC;DBC1 + DB2; DB1 + DBC2;DB1 + DB2
56	简明势态句	jD2J = DB + DC

注：

1. 正文表 3 中的 EJ 是对各种句类代码的抽象表示，具体的句类代码，在本表中表示。附录 B 中的情况相似。
2. 由于句类一般是根据其特征语义块进行命名的，因此同时也借用 EK 表示语句中的特征语义块。特征语义块的具体表示，也在本表中给出。
3. 表示式中等号左边的部分（不含“J”）称为句类代码，等号右边的部分为句类语

义块表示式。

4. 有些句类在句类表示式下方给出了特定语义块的构成表示。语义块名称后、等号的左侧无 J 标记。
5. 无特征语义块句类的句类标记如下：

简明状态句	S04J	集内比较判断句	jD01J
简明势态句	jD2J	参照比较判断句	jD021J，jD022J
简明判断句	jD0J		

6. 1—31 号为广义作用句，38—57 号为广义效应句，32—37 号为两可句类。
7. 在关系句中，一般的 RB 中需要包括 C，如果 RB 明确不含 C，则在句类代码的末尾增加 4 加以表示。

附录 B
（规范性附录）
语句格式代码设计说明

B.1 语句格式

用来表述语句中主语义块在句中的出现顺序，用于语句及其块扩部分和句蜕中。两个语句的概念联想脉络一致，但是主语义块的顺序不同，往往被视为不同的语句。用语句格式结合句类代码，就能表示出其中的相同和不同，即句类代码相同而语句格式不同。这里语句格式最多只考虑四个主语义块的情况，即一个特征语义块、三个广义对象语义块。

B.2 四大类语句格式

根据特征语义块的位置、主语义块标记信息是否完整和主语义块是否省略，语句格式分成四大类：基本格式，规范格式，违例格式和省略格式。主语义块标记信息指语言逻辑概念所涉及的词语，如“把、被、向、对”等就具有这样的义项。英语中使用变格的方式（如“he”的宾格为“him”）指示主语义块位置的变化信息，在语句格式中也作为一种主语义块标记信息进行表示。

B.3 语句格式中的符号

在讨论语句格式时，使用 EJ 表示语句，包括基本句类和混合句类；EK 表示特征语义块，GBK 表示广义对象语义块，其后的数字表示第几个广义对象语义块。这是对句类代码中具体主语义块名称的抽象。对具体句类代码，则这些符号具有特定的含义，如对 XJ，EK 就是 X，GBK1 就是 A，GBK2 是 B；对于 XY40*21J，EK 就是 XY40，GBK1 就是 A，GBK2 是 Y4C。这种抽象还可以根据语句中主语义

块的个数，将语句称为两块句、三块句和四块句等，如 XJ 和 XY40*21J 都是三块句。整个语句代码可以划分成四个部分：格式大类，即属于四类中的哪一类；各主语义块的位置信息；主语义块的冗余标记信息，分别用 7、8、9 表示 GBK1、GBK2 和 GBK3 前有冗余信息；主语义块的变格信息，分别用 01、02、03 表示 GBK1、GBK2 和 GBK3 变格。在四类格式中，省略格式需要同其他三类格式连用，而其他三类格式之间不能连用。

B.4 语句格式编码

语句格式以“!”为开始标志，分别以其后的 0、1、2、3 表示基本、规范、违例和省略格式。对于两块句和三块句，如果要表示主语义块顺序的前后倒置、中间不变，应在“!”前加“^”表示。省略格式与其他三类格式连用时，“!”只作为整体的开始标志，不出现在其他三类格式前。

B.5 基本格式

基本格式的标志是特征语义块位于第二个语义块的位置。基本句类的! 0 格式主语义块顺序与基本句类表示式给出的顺序一致，混合句类与此类似。如果语句采用! 0 格式，语句格式代码应省略不写。不符合上述约定的，在! 0 后添加数字具体说明：0 后的第二位表示特征语义块左侧是第几个 GBK，第三位表示特征语义块右侧 GBK 的情况。下面是具体约定：

——由于! 01 的含义与! 0 相同，所以没有! 01 格式。! 011 表示四块句特征语义块后的 GBK 位置进行了交换，即形成“GBK3 + GBK2”的顺序。

——! 02 除表示 GBK2 位于特征语义块左侧外，还表示特征语义块作了变形，如英语中采用的被动形式，并且约定 GBK1 不出现，即无需恢复 GBK1（对于省略，在分析时需要恢复 GBK1）。! 021 表示 GBK2 和 GBK3 向左移位，GBK2 移到 EK 前，GBK1 循环成为最右侧的 GBK。! 022 只对四块句有效，表示特征语义块右侧的 GBK 位置进行了交换，即形成“GBK1 + GBK3”的顺序。

——! 03 的约定与! 02 的约定类似，但只对四块句有效，除表示 GBK3 位于特征语义块左侧外，还表示特征语义块作了变形，同时 GBK1 不出现。! 031 表示 GBK2 循环成为最右侧的 GBK。! 032 表示特征语义块右侧的 GBK 位置进行了交换，即形成“GBK2 + GBK1”的顺序。

完成主语义块位置的描述之后，需要根据冗余标记出现的情况和 GBK 变格的情况，添加相应的冗余代码和变格代码。

B.6 规范格式

规范格式的标志是特征语义块不位于第二个语义块的位置，同时广义对象语义块之间有语义块标记信息。规范格式中约定为！1mnp，其中 m 表示特征语义块从第二个语义块位置移动的情况：向右移动直接写出移动的位数，向左移动用“4”表示；n 表示第一个出现的广义对象语义块是第 n 个广义对象语义块；p 只出现于四块句中，1 表示第二、三个出现的广义对象语义块是按照自然顺序，即 GBK 脚标小的语义块在前，2 表示第二、三个出现的广义对象语义块交换了位置。在汉语中广义效应句没有规范格式。

B.7 违例格式

除了上述基本格式和规范格式外，在语义块不省略的情况下，其余的格式就是违例格式了。违例格式的特征是特征语义块不位于第二个语义块的位置，同时广义对象语义块之间的语义块标记信息不全或没有。规范格式约定为！2mnp，m、n、p 的含义与规范格式中的相同。另外在违例格式中，对带有语义块标记信息的广义对象语义块，应按照 B.3 的约定指示冗余和变格信息。

B.8 省略格式

省略格式需要与上述介绍的三种格式连用，说明语句在采用上述格式的同时省略了什么主语义块。省略格式约定为！3m，其中 m 表示省略了哪个主语义块，0 表示省略了特征语义块，1～3 对应被省略的广义对象语义块的序号。如果在语句中省略了两个主语义块，则应写成！3m3n，m 和 n 具体说明被省略的主语义块，其余类推。

B.9 其他

在各种格式中，特征语义块是形成格式代码的参照点，对于没有特征的语义块的句类，选择具有 C 语义块基元的语义块作为参照点。如对于简明状态句（S04 句类），选择 SC 作为参照点；对于集内比较判断句（jD01 句类），则以 jDC 为参

照点。

下面举例具体说明上述语句格式代码的编码。例中 GBK 前的“^”表示语义块标记信息，“*”表示语义块变格信息。语句的实际情况按上面的约定进行编码。

B. 10 格式编码示例

A. 1 两主块句

基本格式 ! 0EJ = GBK1 + EK 或 GBK1 + GBK2

^! 0EJ = EK + GBK1 或 GBK2 + GBK1

注：“GBK1 + GBK2”是针对无特征语义块的句类的。

三主块句

基本格式 ! 0EJ = GBK1 + EK + GBK2

^! 0EJ = GBK2 + EK + GBK1

! 002EJ = GBK1 + EK + *GBK2

! 02EJ = GBK2 + ^EK

! 021EJ = GBK2 + ^EK + GBK1

规范格式 ! 111EJ = GBK1 + ^GBK2 + EK

! 112EJ = GBK2 + ^GBK1 + EK

! 141EJ = EK + GBK1 + ^GBK2

! 142EJ = EK + GBK2 + ^GBK1

违例格式 ! 211EJ = GBK1 + GBK2 + EK

! 212EJ = GBK2 + GBK1 + EK

! 241EJ = EK + GBK1 + GBK2

! 242EJ = EK + GBK2 + GBK1

! 2418EJ = EK + GBK1 + ^GBK2

! 2427EJ = EK + GBK2 + ^GBK1

! 241801EJ = EK + *GBK1 + ^GBK2

! 242702EJ = EK + *GBK2 + ^GBK1

四主块句

基本格式 ! 0EJ = GBK1 + EK + GBK2 + GBK3

! 002EJ = GBK1 + EK + *GBK2 + GBK3

! 09EJ = GBK1 + EK + GBK2 + ^GBK3

! 089EJ = GBK1 + EK + ^GBK2 + ^GBK3

```
! 0902EJ = GBK1 + EK + *GBK2 + ^GBK3
! 011EJ = GBK1 + EK + GBK3 + GBK2
! 0118EJ = GBK1 + EK + GBK3 + ^GBK2
! 011802EJ = GBK1 + EK + GBK3 + ^*GBK2
! 01189EJ = GBK1 + EK + ^GBK3 + ^GBK2
! 0118902EJ = GBK1 + EK + ^GBK3 + ^*GBK2
! 02EJ = GBK2 + ^EK + GBK3
! 021EJ = GBK2 + ^EK + GBK3 + GBK1
! 0217EJ = GBK2 + ^EK + GBK3 + ^GBK1
! 02179EJ = GBK2 + ^EK + ^GBK3 + ^GBK1
! 0219EJ = GBK2 + ^EK + ^GBK3 + GBK1
! 022EJ = GBK2 + ^EK + GBK1 + GBK3
! 0229EJ = GBK2 + ^EK + GBK1 + ^GBK3
! 02279EJ = GBK2 + ^EK + ^GBK1 + ^GBK3
! 03EJ = GBK3 + ^EK + GBK2
! 0302EJ = GBK3 + ^EK + *GBK2
! 038EJ = GBK3 + ^EK + ^GBK2
! 031EJ = GBK3 + ^EK + GBK1 + GBK2
! 03178EJ = GBK3 + ^EK + ^GBK1 + ^GBK2
! 0317802EJ = GBK3 + ^EK + ^GBK1 + ^*GBK2
! 0318EJ = GBK3 + ^EK + GBK1 + ^GBK2
! 031802EJ = GBK3 + ^EK + GBK1 + ^*GBK2
! 032EJ = GBK3 + ^EK + GBK2 + GBK1
! 03202EJ = GBK3 + ^EK + *GBK2 + GBK1
! 0327EJ = GBK3 + ^EK + GBK2 + ^GBK1
! 032702EJ = GBK3 + ^EK + *GBK2 + ^GBK1
! 03278EJ = GBK3 + ^EK + ^GBK2 + ^GBK1
```

规范格式

```
! 1111EJ = GBK1 + ^GBK2 + EK + GBK3
! 1112EJ = GBK1 + ^GBK3 + EK + GBK2
! 1121EJ = GBK2 + ^GBK1 + EK + GBK3
! 1122EJ = GBK2 + ^GBK3 + EK + GBK1
! 1131EJ = GBK3 + ^GBK1 + EK + GBK2
! 1132EJ = GBK3 + ^GBK2 + EK + GBK1
```

```
! 1211EJ = GBK1 + ^GBK2 + ^GBK3 + EK
! 1212EJ = GBK1 + ^GBK3 + ^GBK2 + EK
! 1221EJ = GBK2 + ^GBK1 + ^GBK3 + EK
! 1222EJ = GBK2 + ^GBK3 + ^GBK1 + EK
! 1231EJ = GBK3 + ^GBK1 + ^GBK2 + EK
! 1232EJ = GBK3 + ^GBK2 + ^GBK1 + EK
! 1411EJ = EK + GBK1 + ^GBK2 + ^GBK3
! 1412EJ = EK + GBK1 + ^GBK3 + ^GBK2
! 1421EJ = EK + GBK2 + ^GBK1 + ^GBK3
! 1422EJ = EK + GBK2 + ^GBK3 + ^GBK1
! 1431EJ = EK + GBK3 + ^GBK1 + ^GBK2
! 1432EJ = EK + GBK3 + ^GBK2 + ^GBK1
```

违例格式

```
! 2111EJ = GBK1 + GBK2 + EK + GBK3
! 2112EJ = GBK1 + GBK3 + EK + GBK2
! 2121EJ = GBK2 + GBK1 + EK + GBK3
! 2122EJ = GBK2 + GBK3 + EK + GBK1
! 2131EJ = GBK3 + GBK1 + EK + GBK2
! 2132EJ = GBK3 + GBK2 + EK + GBK1
! 2211EJ = GBK1 + GBK2 + GBK3 + EK
! 22119EJ = GBK1 + GBK2 + ^GBK3 + EK
! 22118EJ = GBK1 + ^GBK2 + GBK3 + EK
! 2212EJ = GBK1 + GBK3 + GBK2 + EK
! 22128EJ = GBK1 + GBK3 + ^GBK2 + EK
! 22129EJ = GBK1 + ^GBK3 + GBK2 + EK
! 2221EJ = GBK2 + GBK1 + GBK3 + EK
! 22219EJ = GBK2 + GBK1 + ^GBK3 + EK
! 22217EJ = GBK2 + ^GBK1 + GBK3 + EK
! 2222EJ = GBK2 + GBK3 + GBK1 + EK
! 22227EJ = GBK2 + GBK3 + ^GBK1 + EK
! 22229EJ = GBK2 + ^GBK3 + GBK1 + EK
! 2231EJ = GBK3 + GBK1 + GBK2 + EK
! 22318EJ = GBK3 + GBK1 + ^GBK2 + EK
! 22317EJ = GBK3 + ^GBK1 + GBK2 + EK
```

```
! 2232EJ = GBK3 + GBK2 + GBK1 + EK
! 22327EJ = GBK3 + GBK2 + ^GBK1 + EK
! 22328EJ = GBK3 + ^GBK2 + GBK1 + EK
! 2411EJ = EK + GBK1 + GBK2 + GBK3
! 24119EJ = EK + GBK1 + GBK2 + ^GBK3
! 24118EJ = EK + GBK1 + ^GBK2 + GBK3
! 2412EJ = EK + GBK1 + GBK3 + GBK2
! 24128EJ = EK + GBK1 + GBK3 + ^GBK2
! 24129EJ = EK + GBK1 + ^GBK3 + GBK2
! 2421EJ = EK + GBK2 + GBK1 + GBK3
! 24219EJ = EK + GBK2 + GBK1 + ^GBK3
! 24217EJ = EK + GBK2 + ^GBK1 + GBK3
! 2422EJ = EK + GBK2 + GBK3 + GBK1
! 24227EJ = EK + GBK2 + GBK3 + ^GBK1
! 24229EJ = EK + GBK2 + ^GBK3 + GBK1
! 2431EJ = EK + GBK3 + GBK1 + GBK2
! 2432EJ = EK + GBK3 + GBK2 + GBK1
```

《基于概念层次的语句概念结构语料库标注规范（草案）》研制报告

一　研制背景

（一）必要性

汉语语料库建设是汉语语言研究的重要资源，而标注规范的建立则是建设这一资源的纲领和指南，同时也是使用语料库的向导。作为规范，除了指导语料库的标注，推进本学科的研究外，还服务于语言信息处理，并进一步形成文字文本的语义结构标注规范。这一规范在信息时代的今天具有现实意义。

几十年来，服务于计算机自然语言处理的各种理论和计算方法汇集成了计算语言学，其应用领域从机器翻译开始，扩展到自然语言信息处理的方方面面。语言模型经历了从短语结构语法、格语法到功能合一语法的发展；处理策略经历了从“物理符号系统”到“复杂特征集”的进步，同时也积累了大量的研究成果。然而，这些成果不仅对弱形态表现的汉语难以适应，即使对形态表现丰富的西语，所取得的进展也非常有限。面对这样的局面，我国计算语言学界的有识之士早已看到不重视创新性基础研究将带来的严重后果，发出过“必须建立强大的语义描述系统”的呼吁。董振东先生曾明确指出：“从汉语出发建立强大的语义描述系统，不仅对汉语自身有决定性意义，而且对于其他语言系统的研究与开发也会有重大影响，甚至或许会做出重要贡献”。概念层次网络（Hierarchical Networks of Concepts，简称 HNC）理论的创立者黄曾阳先生则更尖锐地指出：“自然语言传统分析模式（含统计模式）的根本弱点在于：它不是描述语言感知过程的适当模式，大胆创新是唯一的出路”。这一创新的立足点是进入语言的深层——语义，以语句为突破单位，在语言概念空间建立起概念联想脉络。HNC 理论的诞生，正是适应这一创新的呼唤。本项目的研究过程就是将 HNC 应用于语料标注的实践并发展这一理论的过程。

（二）意义和作用

语料库是进行语言理解模型研究的基本建设。以 HNC 理论为指导的语料库标注规范，必将推动相关语料库的建设，推动 HNC 的传播，使这一创新理论更全面、更准确地为世人所了解。更进一步，HNC 语料库的建设可以深化多项 HNC 理论成果，如研究句类及语句格式的分布，语句蜕化成的语义块的构成形式分布，语义块扩展成句子的分布以及逗号作为短语分隔符和语句分隔符的分布情况等等。对 HNC 的多项理论成果给出定量的数据描述，使其更好地服务于自然语言理解处理。

电子文本如果能以计算机可读取的方式附着语义结构信息，将有助于海量信息的自动化处理。因此，迫切需要研制形成具有语义特征的语句语料库标注规范。

（三）立项情况

《基于概念层次的语句概念结构语料库标注规范（草案）》（简称《标注规范》）是国家语委“十五”语言文字应用研究项目——“基于语义的语句类型及语料库标注规范研究”的成果。该项目由国家语委于 2002 年 12 月批准立项，项目编号为：ZDI105—43C，由中国科学院声学研究所语言知识处理实验室承担。

二　研制过程

（一）研制

自批准之日起，项目组围绕研究内容开展科研工作，如期完成了研究任务，形成了符合国家标准（《GB/T1.1—2000》）的“基于概念层次的语句概念结构语料库标注规范”。

在本项目实施过程中，主要完成的研究内容和实际达到的研究目标如下：

1. 形成了基于语义的、具有 HNC 句义表示特点的、汉语语句级语料标注规范。主要内容包括：语言空间的直接标注和概念空间语句的 HNC 结构标注。

2. 运用语料标注规范探索标注语料（整篇文章连续语句），在标注过程中验证完善了语料标注规范。

3. 为了更加方便地描述汉英语句形式的变化，对照标注的结果，制定了新版语句格式代码编码方式。新的方式严格遵循规则，可以方便推算出格式的具体形

式，既便于人记忆也便于计算，不用查表。

4. 对汉语语义块的构成情况进行了深入研究，根据其构成特点，将语义块分成句蜕构成和非句蜕构成两大类。对句蜕块，进一步细分为原型、要素、包装和变异四类。对非句蜕语义块，根据构成的复杂情况，分成简单构成和复杂逻辑构成两种形式；进一步研究发现，在复杂逻辑构成中，实际上是串联和并联两种基本形式的一重或多重组合。

5. 进一步明确了混合句类的界定，尤其是对于作用句与效应句的混合句类。经过标注，发现作用句和效应句的混合句类更能体现句子的语义。

6. 利用形成的汉语语料标注规范，探索标注了汉英对照语料。本标注体系可以完全适用于英语的标注。

7. 运用标注的汉英对照语料，发现标注信息有助于改善机器翻译译文的质量。

8. 运用汉语语料标注规范对比汉语句法分析的内容，探索了汉语处理中并联结构、动词兼类和专有名词识别的策略。

9. 运用标注规范和标注的汉英对照语料，探索了汉英机器翻译中的逗号处理。

10. 遵照国标《GB/T1.1—2000》的要求，制定了“基于概念层次的语句概念结构语料库标注规范（草案）”。

11. 为了便于运用形成的规范对语料中的语句进行标注，编制了语料库语句概念结构标注工具软件。这一软件已经能够完成原始语料浏览、语料标注、标注错误检查和标注结果保存等功能，为在语料库加工处理中具体使用这一规范提供了较好的技术手段。

（二）征求意见

本规范（草案）在形成的过程中，主要征求了有关 HNC 自然语言处理研究者的意见，并根据反馈意见对形成的规范（草案）进行了修改。

（三）鉴定

2005 年 1 月 17 日，国家语委科研办在北京组织召开了“十五”语言文字应用研究项目——“基于语义的语句类型及其语料库标注规范研究”成果鉴定会，通过了项目的成果鉴定，并建议将该成果更名为《基于概念层次网络（HNC）的语句深层语料库标注规范》。

根据鉴定委员会的意见，课题组对本标注规范作了进一步的完善，并根据规

范的内容形成示范性语料库。

鉴定专家组组长为周锡令，成员有冯志伟、张普、曹右琦、鲁川、詹卫东。

三　研制原则和方法

（一）原则

本项目研究的理论基础是 HNC 理论。该理论认为：自然语言理解的本质是概念联想脉络激活、扩展、浓缩、转换与存储的全过程运作。激活运作的要点是语句的理解；扩展与浓缩运作的要点是段落与篇章的理解，转换与存储的要点是记忆与学习。语句的理解显然是自然语言理解的基础，但这不等于说，任何一种形式的语句理解处理算法都可以成为自然语言理解的基础。要取得这一资格，就必须把语句理解定位于概念联想脉络运作全过程的激活。HNC 的要点如下：

1. 要把自然语言所表述的知识划分为概念、语言和常识三个独立的层面，对不同层面采取不同的知识表示策略和学习方式，形成各自的知识库系统。

2. 建立网络式概念基元符号体系，即概念表述的数学表示式。这个符号体系或表示式应具有语义完备性，能够与自然语言的词语建立起语义影射关系，同时，它必须是高度数字化的，每一个符号基元（每个字母或数字）都具有确定的意义，可充当概念联想的激活因子。

3. 建立语句的语义表述模式，即语句表述的数学表示式。这一模式的完备性应表现为可表述自然语言任何语句的语义结构，即乔姆斯基所提出的语言深层结构。

HNC 将句义模式称为“句类”。句类包括基本句类和混合句类。基本句类就是语句句义基元。基本句类和语义概念基元体系具有相同的分类基础，便于建立从词汇上升到句类的联想激活。在句类体系中，语义块是构成句子的下一级单位。根据语义块与句类关系的密切程度，可将其分成主语义块和辅语义块，主语义块是句类的函数。

综上所述，语义格建立了句义结构的表述方法。这种句义的表示往往是在句法分析的基础上辅助的语义说明。同时，语义格中没有建立相应的基元体系，很难清晰说明格的数目，对格应用于语义分析造成了阻碍。而 HNC 则建立了基元化的表述体系，可以明确清晰地刻画出句子的语义结构。用 HNC 的观点看，主语义块基元的作用者（A），对象（B）和内容（C）就是格在外延维度上的分解；而句类，则是格在内涵（语义）维度上的分解，具体的格应当是二者的统一。这个

概念已经超出了格的定义，因此 HNC 称其为主语义块。而辅语义块可以类比为可选格。因此，HNC 深化了格语法的概念。不止于此，HNC 的句类还融合了句法的概念，是一个独立的体系，不依附于句法。此外，HNC 还建立了由词语到句类的、便于激活联想的方式。

（二）研究重点与研究方法

根据 HNC 的已有研究成果，本项目的研究重点和难点如下：

1. 制定和完善现代汉语语义块（相当于短语）和句类（相当于句型）的标注规范；

2. 应用上述规范标注语料；

3. 形成汉语语料库的语义标注规范；

4. 研究了语料库标注规范对英语的适应性；

5. 进行了语句概念结构标注与句法标注的对比研究。

在研究过程中，注重将 HNC 已经建立的语句基元——句类体系应用于对语言现象的分析和描述中，尤其注意建立描述规范对其他语种的适应性。本项目使用英语语料作为验证材料。这一方面是语言理解模型研究的需要；另一方面，也是我们的研究走向国际的要求。

上述五点内容中，前三点的研究成果将体现在形成的《标注规范》中。下面着重介绍后两点的研究情况。

——《标注规范》对英语的适应性

英语和汉语语句格式以及构成方式等方面都存在很大差异，因此，不能把汉语研究的成果直接套用在英语上。通过对经过概念结构标注的英文语料的研究工作，发现和总结出了自然语言处理在英语中存在的特点与规律，以此来说明语句概念结构标注对英语是同样适应的，同样有助于对英语进行研究。下面将在经过概念结构标注的语料的基础上，分别从句类、句式、逻辑组合结构以及句蜕等方面来分析英语语句。

初步的研究发现，英语中基本句类与混合句类的比例是 62.27:37.73，基本句类的前三位是判断句、作用句和效应句，三者占基本句类的 64.89%（见表 1）。

表1：英语句类分布（按大类）

数量 / 句类	基本句类		混合句类		总　计	
	数量	比例（%）	数量	比例（%）	数量	比例（%）
作用	345	13.26	708	27.22	1053	40.48
效应	315	12.11	18	0.69	333	12.8
过程	38	1.46	12	0.47	50	1.93
转移	198	7.61	101	3.88	299	11.49
关系	167	6.42	118	4.55	285	10.97
状态	166	6.38	23	0.88	189	7.26
判断	391	15.03	1	0.04	392	15.07
合　计	1620	62.27	981	37.73	2601	100

从一级子类来看，英语语句有明显的几个不同于汉语的特点：一是句类有无的不同，如英语没有简明状态句S04J；二是句类分布特征的不同，如基本效应句在汉语语料中的比例是20.32%，远高于在英语语料中的比例6.25%，而作用句XJ在英语语料中的比例是10.16%，远高于在汉语语料中的比例1.51%。另外，一般承受句X10J在汉语语料中的比例（1.82%）相对于在英语语料中的比例（0.39%）也要高出很多（见表2）。

表2：汉英句类分布对比（按一级子类）

编号	句类	数量		比例（%）	
		汉语	英语	汉语	英语
1	XJ	5	26	1.51	10.16
2	X03J	8	10	2.42	3.91
3	X4J	1	1	0.3	0.39
4	X10J	6	1	1.82	0.39
5	X11J	1	4	0.3	1.56
7	X109J	1	1	0.3	0.39

续表

编号	句类	数量		比例（%）	
		汉语	英语	汉语	英语
8	X20J	15	10	4.55	3.91
9	X21J	10	7	3.03	2.73
12	X300J	0	3	0	1.17
13	X31J	7	5	2.12	1.95
15	T0J	2	6	0.61	2.34
16	T2J	1	0	0.3	0
17	T3J	0	5	0	1.95
18	T2bJ	0	2	0	0.78
19	T19J	4	6	1.21	1.82
30	D0J	7	1	2.12	0.39
31	DJ	3	3	0.91	1.17
38	YJ	67	16	20.30	6.25
39	Y0J	32	31	9.70	12.11
40	PJ	2	2	0.61	0.78
41	Pm0J/P0J	2	0	0.61	0
42	P11J	2	1	0.61	0.39
43	P21J/P22J	10	11	3.03	4.30
45	SJ	9	2	2.73	0.78
46	S0J	10	13	3.03	5.08
49	Jd00J	7	7	2.12	2.73
50	JD02J	4	3	1.21	1.17
51	jDJ	77	71	23.33	27.73
52	JD1J	9	8	2.73	3.13
57	S04J	18	0	5.45	0
总计	30	330	256	100	100

从上面的分析可以看出，对经过了概念结构标注的语料的分析，HNC 句类分类体系能很好的覆盖所有标注的英语语料，而且发现和总结了英语与汉语在句类分布上的不同之处，从而对探索英语句类特点提供了帮助。

——语句概念结构标注与句法标注的对比研究

句法标注和语句概念结构标注都是为了研究自然语言处理的实际问题，在语料库建设中提出的标注方法，它们是语料库语言学研究的重要课题。句法标注基于句法理论，一般包括词性标注、短语标注以及一些语法功能的标注，集中在语句以下的层面；语句概念结构标注对语义关注更多，而且更多地涉及到语句及其以上的层面。

语料库句法标注的处理目标是对语料文本进行句法分析和标注，形成树库语料。近年来，国内外研究人员在这些方面进行了深入探索，开发完成了许多大规模的树库。在英语方面，有英国的 Lancaster-Leeds 树库和美国的 Penn 树库；德语方面，有 NEGRA 树库和 TIGER 树库；捷克语方面，有布拉格依存树库 PDT；汉语方面，有美国宾州大学的 Penn 中文树库和台北“中研院”的 Sinica 中文树库、清华大学的清华中文树库 TCT、北京大学中文树库、中文语言联盟的汉语句法树库等等。

当今是信息时代，电子文本的获取比以往更加容易，但是如何有效的加工和利用这些语料，是自然语言处理的研究者所面临的严重的挑战。语句概念结构标注与句法标注都是对语料的加工方法，都是为语料库建设服务的。无论是句法标注还是语句概念结构标注，都超越了不同的语法或者语义层次：句法标注不但要标注词性，还要标注短语和句子的结构；语句概念结构标注不但要标注语句的结构，还要标注词语的优先组合、组成语句的语义块的构成和分离、句蜕和块括等特殊语言现象，甚至以后还要标注句群篇章的语境信息。从语料库建设的角度看，语句概念结构标注难度更大一些，所以现在其语料库的规模也要小于基于句法标注的语料库。

句法标注是句法理论的必然产物，对应不同句法理论有不同的标注体系，同样，语句概念结构标注也强烈依赖于概念层次网络（HNC）理论。句法标注的内容基本上都是语言浅层的知识，基本上不涉及或者很少涉及词语、语块和句子的概念含义；语句概念结构标注则不注重具体的词语，而是考察词语映射到语言概念空间的用法和特征，除了关心语句的微观构成，更关心语句组成的宏观结构，力图揭示语句的概念结构和语句的含义的必然联系。句法标注仅仅在语言空间内标注，语句概念结构标注不但要在语言空间内标注，而且还要在语言概念空间标注。

综上所述，通过适应性和对比研究，进一步明确了《基于概念层次的语句概念结构语料库标注规范（草案）》的定位，从而在继承已有的研究成果的基础上，结合语料的实际标注，最终完成了《标注规范（草案）》的制定。

四　研制内容

（一）主要内容与适用范围

语句概念结构标注是在 HNC 理论研究的基础上，具体规定了语句概念结构标注的符号和内容，主要包括：以句类代码形式表述的语句概念结构类型，以语句格式代码表述的语句概念结构中各主要语义块的排列情况，以及以共享句形式表述的语句间主语义块的共享情况。这三项内容以概念联想脉络为基础、以语义块为单元、以语句为基点，清晰地标明了语句内在的概念结构，为发现和探索、提取和验证自然语言理解处理的规律提供了有力的工具。

此外，更大的语言单位诸如句群、段落以及篇章也具有自身的概念结构，对语义表达起着重要的作用，但是目前的大规模标注还不涉及这些语言单位的概念结构。

（二）主要争议问题的处理

在《标注规范》的形成过程中，也存在争议之处。

首先，有关专家认为，将规范命名为“语句深层语料库标注规范”没有体现出本规范的特色和基础，建议将本规范的名称确定为“基于概念层次网络（HNC）的语句深层语料库标注规范”。根据专家的建议，为了能够更具体地体现出“深层”这一概念，最终采用了现在的名称“基于概念层次的语句概念结构语料库标注规范”（简称“标注规范”）。

其次，为了能够比较清晰地确定出语义块的内部构成，在规范研制过程中曾经给出了语义块内部构成的串联和并联表示的内容，经过试用，发现该内容掌握起来有一定的难度，而且手工标注的工作量非常大。因此，在形成规范的时候，调整了这部分内容，只给出了词语优先组合符号，以便给出一些语义块构成的重要信息。

五　其他

本项目的完成是一个良好的开端，但仍然有许多需要进一步深入的问题，比

较迫切和紧要的包括两个方面：

1. 在本项目实施过程中，为了制定语料标注规范，展开了大规模的语料标注，以研究和探索规范的适用性，已经有了比较好的语料积累和基础。如果在规范的实施过程中能够提供示范性标注的语料库，无疑会起到积极的作用。因此，希望在本项目的基础上延续进行以标注规范为基础的示范性语料库的研发工作。

2. 本项目研究的主要内容是关于语句语义的问题，最终形成了语句概念结构的标注规范。在研究中，发现需要将这一内容进一步扩展，继续深入，形成关于句群段落的语料标注规范，将语义研究的内容推进到语境单元——句群层面。目前进行这一研究的条件已经具备。

六　相关资料

（一）参考文献

1. 白殿一，《标准撰写指南》，中国标准出版社　2002 年 9 月．

2. 黄曾阳　杜燕玲　雒自清　郝惠宁，《句群标注与分析》　中科院　声学所．（http：//www. hncnlp. org/010301. htm）．

3. 张全，从 HNC 看主谓句和主谓短语，《第二届 HNC 研讨会论文集》125—131，2004 年 9 月．

4. 张运良，浅析“块”在自然语言理解中的作用，《第二届 HNC 研讨会论文集》132—137，2004 年 9 月．

5. 张全，浅识省略句，《第二届 HNC 研讨会论文集》231—236，2004 年 9 月．

6. 张全，HNC 语料库标注体系浅识，《第二届 HNC 研讨会论文集》282—288，2004 年 9 月．

7. 张全，HNC 语料库的作用，《第二届 HNC 研讨会论文集》289—295，2004 年 9 月．

8. 熊亮，作用效应句在汉英翻译中的句类转换，《第二届 HNC 研讨会论文集》342—349，2004 年 9 月．

9. 熊亮，汉英翻译中因果句的句类转换，《第二届 HNC 研讨会论文集》350—356，2004 年 9 月．

10. 孙雄勇，汉英翻译简明状态句的句类转换研究，《第二届 HNC 研讨会论文集》357—361，2004 年 9 月．

11. 孙雄勇，汉英翻译中一般转换句格式转换，《第二届 HNC 研讨会论文集》，2004 年 9 月．

12. 韦向峰，过渡处理系统的模块设计，《第二届 HNC 研讨会论文集》368—373，2004 年 9 月.

13. 韦向峰，从“坚持”看动词连见，《第二届 HNC 研讨会论文集》417—422，2004 年 9 月.

14. 张全，The Comparison of Semantic Representation between WordNet and HNC，*Advances in Computation of Oriental Languages*，228—234　2003. 7.

15. 韦向峰，SC Transform and Format Transform of Transfer Sentences in Chinese-English MT，*Advances in Computation of Oriental Languages*323—329 2003. 7.

16. 韦向峰，浅析“体词”的“动词”兼类现象，《语言计算与基于内容的文本处理》135—140　2003 年 7 月.

17. 孙雄勇，变异句蜕块的构成分析，《语言计算与基于内容的文本处理》298—303，2003 年 7 月.

18. 张全，汉语和英语逗号的对比分析及其翻译处理，《语言计算与基于内容的文本处理》444—450，2003 年 7 月.

（二）参加工作的单位和人员

研制单位：中国科学院声学研究所

研制负责人：张全

研制人：黄曾阳　张全　张运良　缪建明　韦向峰

参与研制人员：池毓焕　郝惠宁　雒自清　谭露　孙雄勇　吴晨　袁毅　谢法奎　贾宁　熊亮

在本规范（草案）审读过程中，鲁东大学陈淑梅老师和教育部语言文字应用研究所戴红亮老师提出了诸多宝贵的修改意见，在此特别致谢！

《基于概念层次的语句概念结构语料库标注规范（草案）》课题组

2008 年 6 月 6 日