文语转换与语音识别系统语言文字评测规范（草案）

1 范围

本规范（草案）提出了文语转换和语音识别系统评测的一般原则和具体方法。

本规范（草案）可供文语转换和语音识别系统评测参考采用。

2 规范性引用文件

ISO11179－3 信息技术　数据元的规范与标准化　第3部分：数据元的基本属性

GB/T 12200.1　汉语信息处理词汇　01部分：基本术语

GB/T 13725　信息处理用现代汉语分词规范

GB/T 16403－1996　声学　测听方法　纯音气导和骨听阈基本测听法，eqv ISO 8253－1：1989

GB/T 17696－1999　声学　测听方法　第3部分：语言测听，eqv ISO 8253－3：1996

GB/T 16404.1－1996　声学　声强法测定噪声源的声功率级　第1部分：离散点上的测量，eqv ISO 9614－1：1993

GB/T 16404.2－1999　声学　声强法测定噪声源的声功率级　第2部分：扫描测量（Acoustics－Audiometric test methods－Part 3：Speech audiometry），eqv ISO 9614－2：1996

GB/T 13504－1992　汉语清晰度诊断押韵测试（DRT）法（Diagnostic rhyme test（DRT）method of Chinese articulation）

GB/T 16532－1996　通信设备清晰度DRT法评价用语音材料库（Speech material library used DRT for articulation evaluation of communication equipments），idt IEC

728－1：1986

GB/T 17147－1997　声音广播中音频噪声电平的测量，eqv ITU－R 468－4：1990

GB/T 17576－1998 CD　数字音频系统，idt IEC 908：1987

GB/T 14476－1993　客观评价厅堂语言可懂度的 RASTI 法，neq IEC 268－16

GB/T 14919－1994　数字声音信号源编码技术规范（The specifications for digital audio source coding），eqv CCIR 646

GB/T 16463－1996　广播节目声音质量主观评价方法和技术指标要求

SJ 20771－2000　军用通讯系统音质 MOS 评价法

GB3259－92　中文书刊名称汉语拼音拼写法

GB/T 15834－1995　标点符号用法

GB/T 15835－1995　出版物上数字用法的规定

GB/T 16159－1996　汉语拼音正词法基本规则

第一批异形词整理表

第一批异体字整理表

部分计量单位名称统一用字表

中国人名汉语拼音字母拼写法

中国地名汉语拼音字母拼写规则

普通话异读词审音表

3 术语和定义

3.1　语音合成

利用语音库和语音合成技术，自动地合成自然语言的语音流。

3.2　文语转换

把自然语言的文本自动地转换成语音流。语音合成是文语转换的重要组成部分。

3.3　语音识别

利用语音分析技术，抽取语音特征，自动地把自然语言的语音转换成文本。

3.4 词错误率

语音识别系统返回的单词串与标准答案中的正确单词串的差别的比率。

3.5 黑箱评测

主要根据系统的输入数据与输出结果进行判断的评测。它有助于了解信息处理系统外在的总体性能，又叫做“外在评测”。

3.6 白箱评测

对自然语言信息处理系统的内部机制分别进行分析，逐一评测系统的各个组成部分的性能。它有助于了解信息处理系统内部组成部分的性能，又叫做“内在评测”。

4 自然语言信息处理系统评测的一般原则和方法

4.1 评测原则

4.1.1 公平公正原则

评测应努力做到公平、公正。

4.1.2 遵循标准原则

评测应遵循国际标准、国家标准和相关语言文字规范。

4.1.3 人机结合原则

在当前条件下，以人工评测为主，辅之以机器自动评测，做到人工评测与机器评测相结合。

4.1.4 区别对待原则

针对不同语言信息处理系统和用户类型的特点，区别对待，以突出不同系统和用户类型的特殊要求。

4.1.5 灵活柔性原则

语言文字具有一定的灵活性和柔性，有时可容许两种或多种可能的结果并存。

4.1.6 可操作性原则

评测应是可操作的，评测时，应具体地说明评测的方法、步骤和评分方式。

4.2 评测方法

4.2.1 主要方法

自然语言信息处理系统的语言文字评测基本上只涉及系统的外在的总体性能，主要采用黑箱评测的方法。

4.2.2 “宽进严出”策略

对自然语言信息处理系统的输入和输出应区别对待，采用“宽进严出”的策略。系统的输入部分应允许存在不规范之处；系统的输出部分应严格规范。

5 文语转换系统的评测

5.1 文语转换主要内容及测试范围

5.1.1 非正式测试

在正式进行文语转换系统评测前，一般要对语音编码器进行一些非正式的测试，主要包括语音编码器的信噪比测试或频谱间距测试等。当这些测试都达到要求后，还要对原始语音进行比较，对各种语音编码器进行比较。

5.1.2 文语转换系统评测范围

正式的文语转换系统评测包括语音学模块评测和语言学模块评测两部分。

5.1.3 语音学模块评测内容

语音学模块评测包括语音清晰度测试和语音自然度测试。语言学模块评测包括切词、多音字、数字串、符号和单位等的文本处理能力的测试。

5.2 语音学模块评测

语音学模块评测包括语音清晰度测试和语音自然度测试两部分。语音清晰度指输出语音是否容易听清楚，语音自然度指输出语音听起来是否自然。语音清晰度测试又可进一步分为音节清晰度测试、单词清晰度测试和单句清晰度测试。

5.2.1 音节清晰度测试

5.2.1.1 测试方法主要有诊断性押韵测试法（DRT）和改进的押韵测试法（MRT）两种。

5.2.1.2 诊断性押韵测试法：根据国家标准《GB/T 13504－1992 汉语清晰度诊断押韵测试（DRT）法》和《GB/T 16532－1996 通信设备清晰度 DRT 法评价用

语音材料库》来进行汉语音节清晰度测试。测试时，一般以三个音节为一组，每个组为一个文本文件。如下面是 DRT 音节表的一部分：

第 1 组是选汉因

第 2 组是英知绑

第 3 组是狗说更

5.2.1.3　改进的押韵测试法：MRT 是一种改进的押韵测试法。测试时，一般以一个音节为一组，每个组为一个文本文件。MRT 测试法的结果可作为 DRT 测试法的参考。如下面是 MRT 音节表的一部分：

1　我读元字

2　我读习字

3　我读住字

5.2.2　单词清晰度测试

5.2.2.1　采用“语义不可预测句”（SUS）来测试单词清晰度。采用语义不可预测的方式，就可避免根据上文来猜测，并且可在一定程度上削弱学习效应。

如：

1	隔壁	电报	懂	扣子
2	少有的	服务	蒸	飞机
3	学问	房子	洗	锤子
4	老太太	拥护	白	道德
5	爷爷	下去	一	碟子

5.2.2.2　在编制单词清晰度测试题目的时候，应注意参照《普通话异读词审音表》（1985 年 12 月修订），选择一些《普通话异读词审音表》中规定须区分读音的单词，如在“供给、供销、提供”中的“供”读为［gōng］，在“口供、翻供、上供”中的“供”读为［gòng］；在“银行”中的“行”读为［háng］，在“行人”中的“行”读为［xíng］。在测试题目的单词中，还应注意词形的规范，参照《CF1001－2001 第一批异形词整理表》，使用推荐词形。如，“毕恭毕敬”和“必恭必敬”，应使用推荐词形“毕恭毕敬”，“奢靡”和“奢糜”，应使用推荐词形“奢靡”。

5.2.3　单句清晰度测试

5.2.3.1　语义可预测句测试

a. 主要测试单句中语调的清晰性和单句类型的差异性，采用语义可预测的句子编制句表来进行测试。

b. 在测试单句清晰度时，应注意区分单句的类型（如陈述句、命令句、感叹

句、疑问句），注意测试标点符号对于句子语音清晰度的影响。

如：

1 经济起飞像神话似的创造出了奇迹。

2 他成了大学教授，不忘人民养育之恩。

3 在人的一生中，机会可遇而不可求！

4 通过国旗法进行爱国主义思想教育。

5 实验失败了32次，难度可想而知。

c. 在编制句表时，应注意选择一些《普通话异读词审音表》中规定须区分读音的单词，并注意词形的规范，使用推荐词形。

5.2.3.2 语义不可预测句测试

单句清晰度也可采用语义不可预测句子来测试，避免听音人根据上文猜测下文和学习效应等弊病，以提高单句清晰度测试的准确性。这些句子在构成上符合语法，且尽可能覆盖测试语种的典型语法结构。但在语义上，是独立于上下文的，是不可预测的，可更客观地测试单句的清晰度。

5.2.4 语音自然度测试

5.2.4.1 语音自然度测试主要测试合成语音的拟人性、连贯性和韵律感。

a. 语音的拟人性：考察合成语音是否与人的语音接近。

b. 语音的连贯性：考察合成语音是否连贯，节奏与停顿是否自然，语速是否正常，发音是否流利。

c. 语音的韵律感：考察合成语音的语调、重音的位置、轻声和儿化是否正确，听起来是否费力。

5.2.4.2 语音自然度的测试一般以短文作为测试材料。短文集合可根据领域来分类，分为通用领域测试短文集合和特定领域测试短文集合。

5.2.4.2.1 通用领域测试短文集合

由不同体裁的若干段短文组成，短文长度控制在50—200个字以内。

如：

吃什么，怎么吃？这个本来十分简单的问题，现在正困扰着拥有5000年历史的中国人。在城市，在沿海地区，在富裕起来的农村，有80%的家庭主妇对一日三餐感到头疼。在不断加快的生活节奏冲击中，不能忍受长时间背着做饭重担，一生长在厨房里重复劳动。但是，自己不做饭又到哪里去吃？大的饭店太贵，吃不起；小餐馆的价格倒便宜，可不卫生。

5.2.4.2.2 特定领域测试短文集合

由若干个欢迎语、提示语、情景对话、信息服务内容的片断组成，它们一般

与赛事报道、天气预报、交通、旅游、餐饮服务领域相关。短文长度控制在50—200个字以内。

a. 关于交通的短文，如：

从今天开始，北京地铁将延长运营时间，其中2号线地铁运营延长时间多达82分钟。具体运营时间为：1号线：苹果园站首班车5:10，末班车23:30；四惠东站首班车5:05，末班车23:50。2号线：积水潭站首班车5:10，末班车次日0:18。13号线：西直门站首班车6:00，末班车21:45。

这段短文中，要测试时间的读法。如，“23:30”要读为“二十三点三十分［èr shí sān diǎn sān shí fēn］”，“5:10”要读为“五点十分［wǔ diǎn shí fēn］”。

b. 关于赛事的短文，如：

本主题可为您提供参赛者、参赛队、体育场馆以及赛程安排的详细信息。您可通过输入运动员或运动队的名称来获得他们的信息。

在出征巴黎之前，中国队预定的目标是三枚金牌，但在本届世乒赛全部五个单项的角逐中，中国队获得女单、女双、男双、混双四个项目的金银牌，还包揽了混双项目的前四名。男子单打虽然未能获得冠军，但孔令辉、马琳、王励勤都是在关键局的比赛中意外失手，本身具备了获得冠军的实力。

在这些短文中，要测试体育赛事的一些术语的切词是否正确，如“参赛者、赛程、女单、女双、男双、混双”等；人名的切词是否正确，如“孔令辉、马琳、王励勤”等，以保证合成短文的自然度。

c. 关于天气预报的短文，如：

预计，本周全国大部地区以晴到多云天气为主；华北北部和东北地区的气温将比常年同期偏低，我国其它大部地区气温接近常年或偏高。北京地区具体预报如下：9月30日至10月1日，有降雨，降雨量一般有3～15毫米。10月2至4日，北京天气以晴为主，奥运村地区和主场馆温度19至25℃，丰台棒球中心温度18至24℃，昌平赛马场温度16至23℃。

这段短文中，要测试“～”的读法，应读为“到［dào］”或者“至［zhì］”，还要测试温度的读法，例如，“25℃”要读为“二十五摄氏度［èr shí wǔ shè shì dù］”。

5.2.5 语音清晰度评分方法

音节清晰度采用DRT或MRT方法测试，单词、单句清晰度采用SUS方法测试。收集完所有系统的合成语音后，打乱顺序播放，由听音人对合成语音的结果测试进行打分，按百分比进行评分。

a. DRT和MRT测试时，听音人要辨识语音合成结果中的音节，正确辨识的音

节数量越大，错误辨识的音节数量越小，音节辨识的效果就越好，最后得分可按下式计算：

$$P = 100 \times (R - W)/T$$

注：其中 R 是正确辨识的音节数量，W 是错误辨识的音节数量，T 是总共测试的音节数量，P 是清晰度辨识的得分。

b. 测试单词清晰度时，听音人要辨识语音合成结果中的单词，应按单词来判断正误；对于双音节词或多音节词，若其中一个音节错，则判该词为错。

c. 测试单句清晰度时，听音人要辨识语音合成结果中的句子，应按句子来判断正误，听音人记录每一短句中如有一个关键词错误即判为全句错。

单词和单句清晰度的得分按下式计算：

$$P = 100 \times R/T$$

注：根据这个公式计算得出的 P 的比计算 DRT 和 MRT 测试时得出的 P 要宽一些，因为音节识别比单词识别和单句识别相对容易。

5.2.6 语音自然度评分方法

5.2.6.1 两两比较评分法（PC）

同一段短文，如参测系统为 n 个，每个系统的语音合成结果都要和其他的 n－1 系统的合成结果对比，这样共有 n（n－1）/2 个对比组合。m 段短文就有 n（n－1）m/2 个两两对比组合（每个组合由 A 和 B 组成，A，B 表示同一段短文的不同的语音合成系统的合成版本）。听音人按照拟人性、连贯性、韵律感等因素对合成结果采用五级评分制（+2，+1，0，－1，－2）评分，评分标准见表 1：

表 1：两两比较评分法的评分标准

比较结果	A 得分	B 得分
A 比 B 好	+2	－2
A 比 B 稍微好	+1	－1
A 和 B 不相上下	0	0
A 比 B 稍微差	－1	+1
A 比 B 差	－2	+2

5.2.6.2 平均评价分（MOS）评分法

a. MOS 评分法对于听音人要求较高，最好邀请有经验的听音专家参与评分。听音专家根据语音合成结果的输出与自然语言接近程度的总体印象，从拟人性、

连贯性、韵律感等方面，用优、良、中、差、劣五级记分来评价，言语自然度评价的 MOS 分级为：

1—劣，不能接受；

2—差，不愿接受；

3—中，可接受；

4—良，愿意接受；

5—优，很自然。

参测系统各段得分平均作为其自然度得分。

b. 评分时，以 PC 法的评分为主，以 MOS 法的评分为辅。

c. 在用 MOS 法评分时，如听音专家不清楚五级记分的具体表现就可能出现大的方差。可把好的语音和坏的语音例子让听音专家先听一下，然后再开始测试打分。在同样的测试条件下，在不同国家用本土语言，听音专家不容易在等级定位上取得相互一致。因此 MOS 需要进行调整之后，才可得到可靠的品质指标。

5.3 语言学模块评测

语言学模块评测包括：切词、多音字、数字进位制、符号与单位（所有键盘符号、常用化学物理符号及计量单位）等的文本处理能力。

5.3.1 切词

经过文语转换系统后输出的拼音文件中，单词边界用空格表示，要特别注意地名和机构名以及术语的切词是否正确，对于汉族人名应以是否符合韵律词的要求进行判断，姓氏和名字应连读而不能分读。如，“毛泽东”应连读为［maozedong］，而不能分读为［mao zedong］。

5.3.2 多音字

应能根据上下文在输出的拼音文件中对多音字给出正确的拼音。如，“参加”和“参差”中的“参”，前者读为［cān］，后者读为［cēn］。要特别注意单独成词的多音字处理，如，“为”“长”等多音字单独成词的时候应分别根据不同的上下文来读音。“他长于写作”中的“长”读为［cháng］，“他长得很高”中的“长”读为［zhǎng］。

5.3.3 姓氏的特殊读音

应能区别姓氏的特殊读音。如，“曾国藩”和“曾经”中的“曾”，前者是姓氏，读为［zēng］，后者读为［céng］。

如：

记者带着这个问题采访了中国食文化研究会会长曾老。这位75岁老人曾参加八路军，四面八方都到过。

其中的两个“曾”，第一个“曾”是姓氏，应读为［zēng］，后一个“曾”应读为［céng］。

5.3.4 数字进位制

对测试材料中的数字串，应按汉语习惯以亿、万、千、百、十为单位读出，如1,254,000,000应读成“十二亿五千四百万［shí èr yì wǔ qiān sì bǎi wàn］”。在输出拼音文本中应给出相应的拼音形式。

如：

这片林子共有14,000棵树。

其中的14,000应读为“一万四千［yī wàn sì qiān］”

5.3.5 年代、时间、电话号码、百分比、分数和小数

应能区分年代、时间、电话号码和特殊数字表示的顺序式读法和进位制读法以及某些特殊读法，并能处理全角的数字符号。

如：

食源开发和物种驯化，中国在4,000年前就开始进行。

其中的“4,000年”应读为“四千年［sì qiān nián］”，采用进位制读法。

美联社16日报道了中国首位进入太空的宇航员安全返回地面。报道说，在环绕地球21个小时后，航天飞船按计划准时着陆。中国的指挥控制中心宣布：中国首次载人航天飞行获得圆满成功。报道说，这次飞行的圆满完成是中国11年载人航天计划取得的最高成就，也是中国赢得世界声望的象征。

其中的“16”应读为“十六［shí liù］”，“21”应读为“二十一［èr shí yī］”，“11”应读为“十一［shí yī］”，都采用进位制读法。

秦朝建立于公元前221年。

其中的“221年”应读为“两百二十一年［liǎng bǎi èr shí yī nián］”，采用进位制读法。

“马克思生于1818年。”

其中的“1818年”应读为“一八一八年［yī bā yī bā nián］”，采用顺序式读法。

“研讨会定于12月23日上午9:35开幕。”

其中的“12”，“23”都采用进位制读法，分别读为“十二［shí èr］”和“二十三［èr shí sān］”，“9:35”表示时点，应读为“九点三十五分［jiǔ diǎn sān shí wǔ fēn］”。

“旅游投诉电话是9258。”

其中的9258应读为“九二五八［jiǔ èr wǔ bā］”，采用顺序式读法。

有80%的家庭主妇对一日三餐感到头疼。

其中的“80%”应读为“百分之八十［bǎi fēn zhī bā shí］”。

美国太空发展经费占全球约80.2%。

其中的“80.2%”应读为“百分之八十点二［bǎi fēn zhī bā shí diǎn èr］”

他的年龄是我的1/2。

其中的“1/2”应读为“二分之一［ér fēn zhī yī］”。

2/5等于0.4。

其中的“2/5”应读为“五分之二”，“0.4”应读为“零点四［líng diǎn sì］”。

我将住5~8天。

其中的“5~8”应读为“五到八［wǔ dào bā］”或者“五至八［wǔ zhì bā］”。

5.3.6 符号与单位

对测试材料中的符号和单位，有中文法定计量单位的应给出相应的拼音形式，并按汉语普通话读音，读音应遵照《关于在我国统一实行法定计量单位的命令》（1984年）的规定；一般外文符号可按原文给出，按原文读音。

例句1：

1987年7月肯德基前门餐厅开业，门脸儿招牌上KFC三个大字，远远儿就瞧见了。顾客排队最长达20m，中午就餐最多达3000—4000人，真有人驱车20km从通县来的，够火的吧！

其中的“20m”应读为“二十米［èr shí mǐ］”；“20km”应读为“二十公里［èr shí gōng lǐ］”。

例句2

中国选手获得男子举重60kg级冠军。

其中的60kg应读为“六十公斤［liù shí gōng jīn］”

例句3

声音在空气中传播的速度是340米/秒。

其中的“340米/秒”应读为“三百四十米每秒［sān bǎi sì shí mǐ měi miǎo］”。

例句4

比热容单位（焦耳每千克开尔文）的国际符号是J/(kg.K)。

其中的J/(kg.K)应按英文字母读音。

5.3.7 以西文字母开头的词语

以西文字母开头的词语西文字母部分按西文读音，汉字部分按汉语普通话读音。如，“α粒子”应读为［alfa lì zǐ］，“B超”应读为［B chāo］，“ATM机”应读为［ATM jī］。

5.3.8 “一”“不”的读音：在文语转换时，要使用相应的算法根据上下文推出它们的发音变体。

a. “一”在非去声前变为去声

b. “一”“不”在去声前变为阳平

c. “一”“不”夹在词语中间时变为轻声

5.3.9 上声变调：上声在语流中发生音变，在文语转换时要用相应的算法根据上下文推出它们的发音变体，主要应处理如下的现象。

a. 上声在非上声（阴平、阳平、去声）前一律变为平上，调值由原来的［ˊ ˉ ˇ ˋ］变为［ˊ ˉ］，只降不升。如，“影星，影评，影印”中的“影”应读为平上。

b. 上声在上声前（上上相连），前一个上声变得像阳平，调值由［ˊ ˉ ˇ ˋ］变为［ˊ ˇ］，只升不降。如，“本领，讲解，导演”中的“本，讲，导”调值为［ˊ ˇ］。

5.3.10 轻声的读音：普通话的轻声具有区别意义的作用，在语音合成的评测中，应注意评测如下要点：

a. 辨义轻声：同一个汉字，由于是否读轻声而导致语义不同。如，“老子”读轻声时表示骄傲的自称，不读轻声时表示古代人名或书名。

b. 连接词“和”读为轻声。

c. 助词“的、地、得”读为轻声。

d. 方位结构中的非中心音节读为轻声：如，“眼里、手上、乡下”中的“里、上、下”读为轻声。

e. 双字重叠的指人名词，后一个音节读为轻声。如，“哥哥、妈妈、婆婆”中的后一个音节“哥、妈、婆”读为轻声。

f. 单音节动词重叠式的后一个音节读为轻声。如，“看看、洗洗、说说”中的后一个音节“看、洗、说”读为轻声。

5.3.11 儿化的读音

儿化音对于语音合成的自然度有重要的作用，在语音合成中，应对儿化进行系统化的处理：

a. 于有区别意义作用的儿化词，须按儿化读音。如，

信（表示“信件”）—— 信儿（表示“消息”）

头（表示“脑袋”）—— 头儿（表示“领头的人”）

b. 对于有区别词性作用的儿化词，须按儿化读音。如，

盖（动词）——盖儿（名词）

尖（形容词）——尖儿（名词）

c. 对于表示感情色彩的儿化词，尽量按儿化读音。如，

小孩——小孩儿

好玩——好玩儿

d. 语音词典中，应对上述儿化词一一标注拼音，儿化词中的音节数等于汉字字数减一。如，“花儿”应标注为［huar］，其音节数为1，不能标注为［hua'er］。

e. 当自动切词得到后缀“儿”时，将“儿”与前面的单词合并，并把前面单词的最后一个音节儿化，语音合成时“儿”不再发音。

f. 非儿化词中的“儿”，应单独读成一个音节。如，“孤儿、男儿、混血儿”中的“儿”，都应读成一个音节，不能儿化。

5.3.12　专有名词的读音

语音合成和文语转换的很多应用都与专有名词分不开的；如在与电话有关的应用中，电话簿和打电话都离不开人名和地名，汉语专有名词有的读音很特殊，应注意区别。如，“单”作为姓时应读为［shàn］，不能读为［dān］。地名“枞阳”中的“枞”应读为［zōng］，不能读为［cōng］。

5.3.13　专业术语的读音

把语音技术应用于不同的专业领域需要正确处理专业术语的读音。如，地貌学术语“潟湖”（浅水海湾因湾口被淤积的泥沙封闭而形成的湖）中的“潟”应读为［xì］，不读为［xiè］。

6　语音识别系统的评测

语音识别的目的是让计算机通过识别和理解把语音信号转变为相应的文本或命令。

6.1　测试样本和发音人的选择

进行语音文本转换和音节转换测试时，应采用包含一定数量句子的汉语普通

话样本，由发音人朗读，作为测试数据。测试样本中有标点，在录音时，约定标点不发音，但应有适当停顿。

选择样本的发音人时应注意：

a. 适当的性别搭配，以便反映发音时性别的差异：例如，发音人可男女各半，男 10 人，女 10 人。

b. 适当反映方言的特点，以便测试计算机是否能够识别带有方言色彩的普通话。

6.2 语音文本转换测试与音节测试

6.2.1 语音文本转换测试的目的是测试非特定人的、无限词汇的、以朗读方式读出的汉语普通话连续语音识别技术，输入是语音信号，输出是相应的文本或者命令。

6.2.2 音节测试的目的是测试语音识别系统的算法。测试时，输入是无调的语音串，输出是相应音节的拼音形式，可输出多组不同音节来测试算法的功能。

6.3 语音识别的评测指标

6.3.1 语音文本转换评测指标

a. 语音文本转换的评测指标是参照自然语言处理中“词错误率”（WER）的概念设计的。

- 汉字正识率 = 正确汉字数/标准答案汉字总数 ×100%；
- 插入汉字错误率 = 插入错误汉字数目/标准答案汉字总数 ×100%；
- 删除汉字错误率 = 删除错误汉字数目/标准答案汉字总数 ×100%；
- 替换汉字错误率 = 替换错误汉字数目/标准答案汉字总数 ×100%；

例如，对于如下的语音文本转换结果：

标准答案：	历	时	三	天	三	夜	*	顾	不	上	休	息
识别结果：	历	*	三	田	伞	也	勾	顾	布	尚	休	息
评估：			D		S	S	S	I		S	S	

其中，标准答案汉字数为 11，识别结果有 5 个替代（S），1 个插入（I），1 个删除（D），正确识别汉字数为 5：

$$汉字正识率=\frac{5}{11}\times100\%=45.45\%$$

$$插入汉字错误率=\frac{1}{11}\times100\%=9.09\%$$

$$删除汉字错误率=\frac{1}{11}\times100\%=9.09\%$$

$$替换汉字错误率=\frac{5}{11}\times100\%=45.45\%$$

b. 还要评测如下指标：

· 句子正识率 = 正识(一字不差)句子数/句子总数 × 100%；

· 完成时间 = 系统完成全部任务所用的时间；

· 系统故障数 = 在评测过程中测试系统出现故障的次数。

6.3.2 音节识别评测指标

6.3.2.1 参照语音文本转换的评测指标，音节识别的评测指标如下：

a. 音节正识率 = 正确音节数/标准答案音节总数 × 100%；

b. 插入音节错误率 = 插入错误音节数目/标准答案音节总数 × 100%；

c. 删除音节错误率 = 删除错误音节数目/标准答案音节总数 × 100%；

d. 替换音节错误率 = 替换错误音节数目/标准答案音节总数 × 100%；

示例：对于如下的音节识别结果：

标准答案：	lí	shí	sān	tiān	sān	yè	*	gù	bù	shàng	xiū	xí
识别结果：	lí	*	sān	tián	sǎn	yě	gōu	gù	bù	shàng	xiū	xí
评估：			D	S		S	S	I				

其中，标准答案音节数为 11，识别结果有 3 个替代（S），1 个插入（I），1 个删除（D），正确识别音节数为 7：

$$音节正识率=\frac{7}{11}\times100\%=63.63\%$$

$$插入音节错误率=\frac{1}{11}\times100\%=9.09\%$$

$$删除音节错误率=\frac{1}{11}\times100\%=9.09\%$$

$$替换音节错误率=\frac{3}{11}\times100\%=27.27\%$$

6.3.2.2 还要评测如下指标：

a. 完成时间 = 系统完成全部任务所用的时间；

b. 系统故障数 = 在评测过程中测试系统出现故障的次数。

6.3.3 对语音识别系统产生的文本也须进行语言学方面的评测。其内容包括：字形、异形词、同音词、歧义（切分）、儿化词等的处理能力。具体要求如下：

a. 字形：应符合《第一批异体字整理表》《简化字总表》的规定，使用规范字形。要特别注意计量单位的用字，应使用《部分计量单位名称统一用字表》的规定字形。例如，“十四海里/十四浬/十四海浬”，应选用规范的“十四海里”。

b. 异形词：使用《第一批异形词整理表》的推荐词形。例如，“百叶窗”和“百页窗”，应选用推荐词形“百叶窗”；“参与”和“参预”，应选用推荐词形“参与”。

c. 同音词：应能对同音词做出正确识别。例如，“枇杷”和“琵琶”读音完全相同，但在“我爱吃枇杷”中，应能识别为“枇杷”；在“她会弹琵琶”中应能识别为“琵琶”。

d. 歧义（切分）：应能对歧义语音串做出正确识别。例如，对“计算鸡蛋的重量”应能做出正确识别，不能识别为“计算机蛋的重量”。

e. 儿化词：应能对儿化音节进行正确识别，并在文本中给以标识，具体标识方式可灵活处理，如“把盖$_{儿}$盖上”、“把盖（儿）盖上”、“把盖儿盖上”都可，但如果输出为“把盖盖上”，则认为没有正确识别出儿化音节。