机器翻译系统语言文字评测规范（草案）

1 范围

本规范（草案）提出了机器翻译系统的评测的一般原则和具体方法。

本规范（草案）可供机器翻译系统评测参考采用。

2 规范性引用文件

ISO11179—3 信息技术 数据元的规范与标准化 第3部分：数据元的基本属性

GB/T 12200.1	汉语信息处理词汇01部分：基本术语
GB/T 13725	信息处理用现代汉语分词规范
GB3259—92	中文书刊名称汉语拼音拼写法
GB/T 15834—1995	标点符号用法
GB/T 15835—1995	出版物上数字用法的规定
GB/T 16159—1996	汉语拼音正词法基本规则

第一批异形词整理表

第一批异体字整理表

部分计量单位名称统一用字表

中国人名汉语拼音字母拼写法

中国地名汉语拼音字母拼写规则

普通话异读词审音表

文语转换和语音识别系统语言文字评测规范（草案）

3 术语和定义

3.1 机器翻译

利用计算机把源语言翻译成目标语言。

3.2 机器翻译系统

利用计算机把源语言转变成目标语言的软件系统。

3.3 鲁棒性

计算机系统对于错误输入的处理能力以及系统的容错能力。

4 机器翻译系统评测的一般原则和方法

4.1 评测原则

本规范（草案）参照使用《文语转换与语音识别系统语言文字评测规范（草案）》中规定的自然语言信息处理系统评测的一般原则和方法。

4.2 评测方法

主要采用黑箱评测的方法，以人工评测为主，同时逐步采用国际上行之有效的自动评测方法。

5 机器翻译系统的用户类型

5.1 机器翻译的译文质量评测与用户类型有密切关系，机器翻译系统一般可分为如下类型：

a. 为浏览者研制的机器翻译

目的是帮助浏览者查阅外文资料，对于译文质量要求不高，浏览者可接受粗糙的译文。

b. 为修订者研制的机器翻译

目的是帮助用户修订粗糙的译文，粗糙的译文经过修订之后，质量应比为浏览者研制的机器翻译的译文有所提高。

c. 为翻译者研制的机器翻译

目的是帮助用户进行在线机器翻译，用户在翻译时可使用在线机器词典、翻译实例库等，对译文质量的要求比较高。

d. 为写作者研制的机器翻译

目的在于帮助用户进行翻译或写作，要尽量避免翻译中的歧义，对译文质量要求更高。

5.2 根据上述分类，可有针对性地对机器翻译系统进行评测，根据用户类型的不同，评测时考虑不同的评测重点。

6 机器翻译评测题目的编制原则

6.1 评测题目的选取应遵循以下基本原则：

a. 在外汉机器翻译系统中，对作为源语言的外国语，基本上应以相应外国语的大学教学大纲作为测试题目选取的主要依据；在汉外机器翻译系统中，对作为源语言的汉语应以汉语常用句型作为测试题目选取的主要依据。

b. 对通用机器翻译系统的测试，测试题目中的词汇应选自一般领域，侧重在社会、生活、政治、经济、常识等方面，不出冷僻的词，也不出专业性很强的术语；对专业机器翻译系统的测试，测试题目中的词汇和语法结构应体现出不同专业领域的特点。

c. 测试题目中可包含少量的固定词组，但这些固定词组应是常用的，不选罕用的俗语和谚语。

d. 测试题目应注意区别兼类词：兼类词是具有不同词类的词，在机器翻译中应加以区分，使得一个单词只有一个词类标记。区别兼类词是词性标注的基本问题。

如，在英语中，face，use 是“动词－名词”兼类词（V-N 兼类词），may，can，will 是“助动词－名词”兼类词（AUX-N 兼类词），机器翻译系统应加以区别：

face：The houses face the park.（V）

She pulled a long face.（N）

May：May I help you?（AUX）

May Day is first day of May.（N）

can：She can speak German.（AUX）

He opened a can of beans.（N）

e. 测试题目应注意区别多义词或同音词。

多义词是具有多个意义的同一个词，在机器翻译中应注意区分。

如英语的 doctor 是多义词，可翻译为“医生”，也可翻译为“博士”，机器翻译系统应加以区别：

John is a medical doctor.（doctor 应翻译为“医生”）

John is a doctor of philosophy.（doctor 应翻译为“博士”）

同音词是指词形相同而意义不同的两个或两个以上的词。

如英语的 bank 是同音词，其意义可为“河岸”，也可为“银行”，机器翻译系统应加以区别：

He looked at the river bank.（bank 应翻译为“河岸”）

He looked at the money bank.（bank 应翻译为“银行”）

f. 测试题目应有一定数量的用于区别结构歧义的句子，以便测试机器翻译系统分析结构歧义的能力。如英语句子“They made a decision on the boat”中的介词短语 on the boat，既可修饰名词 decision，也可修饰动词 made，从而形成结构歧义。对于这样的具有结构歧义的句子，机器翻译系统应根据有关语言学知识给出一个正确的翻译结果，以显示系统处理歧义结构的能力。再如“He bought a car with four doors”介词短语 with four doors 是修饰名词词组 a car 的，机器翻译系统只可出一个结果。

6.2 测试题目的句子，应选取现代书面语中的规范句子，句子中的单词和语法应严格遵循所测试语言的规范标准。

7 机器翻译的评测标准

7.1 人工评测的标准

人工评测时，可分别就忠实度和可懂度制定评测标准，也可不区分忠实度和可懂度，综合采用可理解度进行评测。评测时注意系统应遵循有关语言文字标准。

7.1.1 忠实度和可懂度的评测标准

a. 忠实度（fidelity）：评测译文是否忠实地表达了原文的内容。按0—5 分打分，打分可含一位小数。最后的得分是所有打分的算术平均值，见表 1。

表1：人工评测的忠实度打分标准

分数	得分标准
0	完全没有译出来
1	译文中只有个别单词与原文相符
2	译文中有少数内容与原文相符
3	译文基本表达了原文的信息
4	译文表达了原文的绝大部分信息
5	译文准确完整地表达了原文信息

b. 流畅度（comprehensibility）：评测译文是否流畅和地道。按0—5分打分，打分可含一位小数。最后的得分是所有打分的算术平均值，见表2。

表2：人工评测的流畅度打分标准

分数	得分标准
0	完全不可理解
1	译文晦涩难懂
2	译文很不流畅
3	译文基本流畅
4	译文流畅但不够地道
5	译文流畅而且地道

7.1.2 综合采用可理解度（intelligibility）进行评测

7.1.2.1 结合忠实度和流畅度，综合采用可理解度来评测。见表3。

表3：人工评测可理解度打分

分数	得分标准	译文可理解度
0	完全没有译出。	0%
1	看了译文不知所云或者意思完全不对，只有小部分词语翻译正确。	20%
2	译文有一部分与原文的部分意思相符；或者全句没有翻译对，但是关键的词都孤立地翻译出来了，对人工编辑有点用处。	40%

续表

分数	得分标准	译文可理解度
3	译文大致表达了原文的意思，只与原文有局部的出入，一般情况下需要参照原文才能改正译文的错误；有时即使无需参照原文也能猜到译文的意思，但译文的不妥明显是由于翻译程序的缺陷造成的。	60%
4	译文传达了原文的信息，不用参照原文，就能明白译文的意思，但是部分译文在词形变化、词序、多义词选择、得体性等方面存在问题，需要进行修改。不过这种修改无需参照原文也能有把握地进行，修改起来比较容易。	80%
5	译文准确流畅地传达了原文的信息，语法结构正确，除个别错别字、小品词、单复数、地道性等小问题外，不存在很大的问题，这些问题只需进行很小的修改；或者译文完全正确，无需修改。	100%

7.1.2.2　评测时按0.0—5.0分打分，可含一位小数，最后采用百分制换算评测结果（总的可理解度＝所有句子得分之和/总句数×100%）。

7.1.3　对于汉外机器翻译系统中汉语原文的具体要求

对于汉译外机器翻译系统，汉语原文应遵循我国已经发布的有关语言文字标准，使用《第一批异体字整理表》《简化字总表》中的规范字形。

7.1.4　对于外汉机器翻译系统中汉语译文的具体要求

7.1.4.1　对于机器翻译系统中的外译汉系统，汉语译文除忠实度、可懂度、可理解度之外，还应符合国家有关语言文字规范，包括字形、异形词、标点符号、术语、人名等的规范。具体要求如下：

a. 字形：经过外译汉机器翻译系统输出的汉语译文在字形方面应符合《第一批异体字整理表》《简化字总表》《部分计量单位名称统一用字表》规定的字形。

b. 异形词：汉语译文对异形词的处理应注意词形规范。

c. 标点符号：汉语译文中的标点符号应注意使用规范，应符合《GB/T15834—1995 标点符号用法》的规定。

d. 术语：外译汉机器翻译系统应注意术语的翻译问题，各学科术语的翻译应使用全国科学技术名词审定委员会已公布的术语。如计算机术语“backup”有“备制/后备/备用/备份”几种译法，应选用“备份”；物理学术语“charm quark”

有“魅夸克/粲夸克”两种译法，应选用“粲夸克”。

e. 人名：外国人名的翻译应遵循“名从主人”“约定俗成”的原则。如法国数学家 Galois 是法国人，其中文译名应遵照“名从主人”的原则，按法语读音规则译为“伽罗华”，而不能按英语读音规则译为“伽罗依斯”；对于熟知的外国人名，可按“约定俗成”的原则，继续沿用旧译名，不宜改动。如笛卡儿（R. Descartes）、伽利略（G. Galilei）、牛顿（I. Newton）；英美人名应以新华社编写的《英语姓名译名手册》或全国科学技术名词审定委员会已公布的译名为准。如诺贝尔文学奖获得者 William Faulkner 有“威廉·福克纳”和“威廉姆·弗格纳”等不同的译法，应根据《英语姓名译名手册》译为“威廉·福克纳”。

7.1.4.2 机器翻译系统还应注意不同风格、不同语体文章的翻译问题。如小说对话的译文应使用口语词汇，而正式文体的译文则应使用书面语词汇。

7.2 自动评测的方法

7.2.1 BLEU 评测方法

a. 这是基于 N 元语法（N－gram）的自动评测方法，它通过对译文跟参考译文进行 N－gram 比较综合而得出译文好坏的评价分数。这种基于 N 元语法共现的统计方法中，一元词的共现代表了翻译的忠实度，它表征了原文里面有多少单词被翻译了过来；而二元以上的共现词汇代表了目标语言的可懂度，阶数高的 N 元词的匹配度越高，系统译文的可懂度就越好。

其基本计算公式为：

$$Score = BP \cdot \exp\left(\sum_{n=1}^{N} w_n \log p_n\right)$$

$$BP = \min\left\{1, \mathrm{epx}\left(1 - \frac{Lref}{Lsys}\right)\right\}$$

b. BLEU 是根据 N－gram 准确率的几何平均值来计算的，得分越高越好。

注：P_n = 被测译文中与参考答案匹配的 N－gram 总数/被测译文中 N－gram 总数；BP = 长度惩罚因子；Lref = 与被测句子长度最接近的答案长度；Lsys = 被评测句子的长度；N = 最大 N－gram 长度；W_n = N－gram 的权重；exp x 表示 e^x，即以自然对数 e 为底的指数函数。

7.2.2. NIST 评测方法

a. NIST 是在 BLEU 标准基础上提出的改进方案，称为 NIST 评测标准。NIST 采用各阶 N－gram 的算术平均值而不是几何平均值，使得总体评价结果更偏重于忠实度，且不至于因某一阶 N－gram 的匹配率为零而导致总体评价为零。另外

NIST 考虑到每一个 N－gram 在多个参考译文中出现的次数不同能够表现出该词的重要性，应根据其在多个参考译文中出现的次数而给每一个 N－gram 赋予一个权值。

下面是 NIST 的基本公式：

$$scorce = \sum_{n=1}^{N} \left\{ \sum_{\substack{\text{all} w_1 \cdots w_n \\ \text{that co-occur}}} Info(w_1 \cdots w_n) \Big/ \sum_{\substack{\text{all} w_1 \cdots w_n \\ \text{in sys output}}} (1) \right\} \cdot \exp\left\{ \beta \log^2 \left[\min\left(\frac{L_{sys}}{\overline{L}_{ref}}, 1 \right) \right] \right\}$$

$$Info(w_1 \cdots w_n) = \log_2 \left(\frac{\text{the\#of occurrences of } w_1 \cdots w_{n-1}}{\text{the\#of occurrences of } w_1 \cdots w_n} \right)$$

注：β 是一个常数，是一个经验阈值，使得在 Lsys/Lref = 2/3 时，β 使得长度罚分率为 0.5；$\overline{L}ref$ 是参考答案的平均长度；其余参数意义与 BLEU 相同。

b. NIST 是根据根据 N－gram 准确率的算术平均值来计算的，得分越高越好。

c. BLEU 和 NIST 的自动评测结果有助于减少人工评测的主观性，对于人工评测有一定参考价值。在机器翻译评测中，建议以人工评测为主，以 BLEU 和 NIST 的评测结果作为参考。

7.2.3　基于最小编辑距离的自动评测方法

最小编辑距离是把一个符号串通过插入、删除和替换三种操作转换成另一个符号串的最小代价。采用数据库存储机器翻译的原文和不同质量级别的多个参考译文，评测时首先把机器翻译的译文对应到与它的编辑距离最小的参考译文，然后再自动估算出译文质量的等级。

7.3　机器翻译译文质量的其他评测方式

还可采用其他的方式来评测机器翻译的译文质量：

a. 根据译后编辑对译文的修改量来进行评测；

b. 把机器翻译的译文同人翻译的译文相比较来进行评测；

c. 把标准换算成费用，根据最终费用的多少来进行评测。

8　机器翻译评测的其他内容

8.1　根据机器翻译所需时间进行评测

由主持评测的工作人员现场记录翻译时间，各系统自动显示从第一个句子翻译开始到所有句子翻译完毕所用的时间（不计系统初始化所用时间，只记开始翻译到所有句子翻译完毕所用时间）。

8.2 根据使用环境的要求来进行评测

对于计算机硬件的要求，可从对其他软件的依赖性，对输入文本的要求，对用户界面的质量等方面进行评测。

8.3 根据可维护性进行评测

评测机器翻译系统能否解决实际应用中出现的问题，能否保证系统的正常运行。

8.4 根据可扩充性进行评测

评测机器翻译系统是否便于扩充系统的词汇和语法结构的覆盖面。

8.5 根据系统的性能价格比进行评测

评测机器翻译系统的翻译速度和译后编辑所需要的时间，以求得最好的性能价格比。

8.6 根据系统的鲁棒性进行评测

评测机器翻译系统对于错误输入原文的处理能力以及系统的容错性。

8.7 根据模块性进行评测

评测机器翻译系统模块各个部分的接口是否清晰，数据与算法是否分开。

8.8 根据单调性进行评测

评测当机器翻译系统升级之后，原来的性能是否会退步，若干独立的升级是否能够彼此结合，避免冲突。