现代汉语语料库元数据规范（草案）

1 范围

本规范（草案）提出了现代汉语语料库元数据的核心元数据集、元数据的命名规则和描述格式。

本规范（草案）可供语料库建设参考采用。

2 术语

2.1 元数据

关于数据的数据，即关于数据的内容、质量、状况和其他特性的信息。

2.2 元数据集

元数据的集合。

2.3 DC 元数据

元数据中的一个标准集—都柏林核心元素集（Dublin Core Element Set），简称为都柏林核心（即 DC），DC 元数据指都柏林核心元数据（Dublin Core Metadata），是一种跨领域的信息资源描述标准。

2.4 OLAC 元数据（Open Language Archives Community Metadata）

开放语言资源组织（Open Language Archives Community）定义的元数据集中的

元数据。

3 总则

3.1 语料库元数据分类

本规范（草案）定义的语料库元数据分为6大类：语料的知识产权信息、语料创建者的背景信息、语料载体的发行信息、语料的内容信息、语料的采集方式信息、语料的管理信息。

3.2 语料库元数据定义格式

本规范草案中，每个元数据的定义包含以下数据项：

—名称（Name）：元数据的唯一标记，保存信息时使用，用英文字母。

—长名（Full Title）：采用完整的中文名称，显示信息时使用。

—定义（Definition）：描述元数据的语义。

—注释（Comments）：与元数据取值、格式等相关的说明。

—值域（Value Land）：元数据可能的取值范围。

—类型（Type）：元数据的类型可为“基本元素”或者“文件引用”。“基本元素”表示该数据项的取值是一个简单数据项，“文件引用”表示这一部分的内容参照一个具体的文件。

—来源（Defined_In）：指明该元数据是由哪个标准或规范最先定义的，如DC元数据、OLAC元数据、自定义元数据等。自定义元数据指本规范（草案）自定义的元数据。

—备注（Remark）：与元数据来源、命名相关的一些补充说明。

3.3 语料库元数据命名原则

3.3.1 如为DC核心元素集中的元数据，则直接用原来的名称。

3.3.2 如为DC核心元素集中的元数据及其修饰词，则在修饰词和核心元素之间用下划线连接命名。

3.3.3 如为OLAC元数据，则直接用原来的名称。

3.3.4 自定义的元数据分三类：

a. 第一类自定义元数据的核心词来源于DC元数据，本规范（草案）增加了

修饰词。如对 DC 元数据“权限（Rights）”增加了两个修饰词，为“原始语料”和“标注语料”，分别记录原始语料的权限和加工后的语料的权限归属。对这一类元数据，采用在修饰词和核心元素之间用下划线连接的方式命名。

b. 第二类自定义的元数据是对 DC 核心元数据某一方面属性的详细描述，如对 DC 元数据“创建者（Creator）”，增加了性别、籍贯等属性的描述。对这一类元数据采用 OLAC 元数据命名的方式，在 DC 元数据和新增的属性之间用符号“.”连接。如 Creator. Sex，表示资源创建者的性别。

c. 第三类自定义元数据是语料库开发时独有的信息，如“标注（Annotation）”，它本身是一个元数据，还可参照前面的规则，在其前面加修饰词或在后面加属性描述，形成新的元数据。

4 元数据集

4.1 语料的知识产权信息

4.1.1 标题

——名称：Title

——长名：标题

——定义：语料原作的标题。

——注释：

——值域：包括书名、文章名、网页名、公文名称等，如是口语语料，也可为录音者取的名称。

——类型：基本元素

——来源：DC 元数据

——备注：

4.1.2 语料来源

——名称：Source

——长名：语料来源

——定义：语料来源的唯一标志信息。

——注释：

——值域：如语料来源是书籍，则取书籍的 ISBN 号、版次、印次；如语料来源是期刊，则取刊名、刊号、期号；如语料来源是网络，则取网页的 URL 号；如语料来自于其他途径，如口语、书信等，也可采用语料库创建者自定义的规则。

——类型：基本元素

——来源：DC 元数据

——备注：

4.1.3 创作时间

——名称：Created_Date

——长名：创作时间

——定义：语料原作的创建时间。

——注释：建议使用 YYYY - MM - DD 格式。如是书面语语料，这一数据取语料原作的写作时间；如是口语语料，这一数据可为录音采样的时间。

——值域：

——类型：基本元素

——来源：DC 元数据

——备注：Date 是 DC 核心元数据，Created 是 DC 元数据中为 Date 定义的修饰词。

4.1.4 出版时间

——名称：Issued_Date

——长名：出版时间

——定义：语料原作作为正式出版物出版的时间。

——注释：建议使用 YYYY - MM - DD 格式。

——值域：

——类型：基本元素

——来源：DC 元数据

——备注：Date 是 DC 核心元数据，Issued 是 DC 元数据中为 Date 定义的修饰词。

4.1.5 原作权限

——名称：Source _Rights

——长名：原作权限

——定义：语料原作所有的或被赋予的权限信息。

——注释：可为一个权限管理的陈述，也可为一个权限管理陈述的标识，或者是提供资源权限管理的服务器的标识。

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：Rights 是 DC 核心元数据，Source 是本规范草案自定义的修饰词。

4.1.6 类型

——名称：Type

——长名：原作类型

——定义：语料原作的物理载体形式或组成材料。

——注释：

——值域：

——类型：基本元素

——来源：DC 元数据

——备注：

4.1.7 覆盖范围

——名称：Coverage

——长名：覆盖范围

——定义：资源内容的时空特征。

——注释：覆盖范围一般包括空间位置、时间区间、权限。

——值域：

——类型：基本元素

——来源：DC 元数据

——备注：

4.2 语料创建者的背景信息

4.2.1 创建者

——名称：Creator

——长名：创建者

——定义：创建者名称。

——注释：可包括一个或多个创建者的姓名或单位名称。

——值域：

——类型：基本元素

——来源：DC 元数据

——备注：

4.2.2 创建者形式

——名称：Creator. Type

——长名：创建者形式

——定义：语料创建者的组织形式。

——注释：语料的创建者可为一个人、多个人或者集体。

——值域：该数据项的值域可参考 BNC 语料库的设计，定义为：{sole，multiple，corporate，unknown，unclassified}，其中，unknown 表示不知道该语料属于哪一类，unclassified 表示这一属性不确定。

——类型：基本元素

——来源：自定义元数据

——备注：

4.2.3 创建者性别

——名称：Creator. Sex

——长名：创建者性别

——定义：创建者性别

——注释：

——值域：语料库的性别字段的值域可设为：{male，female，mixed，unknown}，其中 mixed 表示作者中有男有女，unknown 表示不知道性别。

——类型：基本元素

——来源：自定义元数据

——状态：选择使用

——备注：

4.2.4 创建者籍贯

——名称：Creator. Native_Place

——长名：创建者籍贯

——定义：创建者籍贯

——注释：

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.2.5 母语

——名称：Creator. Native_Language

——长名：创建者母语

——定义：语料原作的创建者使用的母语。

——注释：

——值域：
——类型：基本元素
——来源：自定义元数据
——备注：

4.2.6　创建者年龄

——名称：Creator. Age
——长名：创建者年龄
——定义：语料原作创建者的年龄。
——注释：
——值域：
——类型：基本元素
——来源：自定义元数据
——备注：

4.3　语料载体的发行信息

4.3.1　媒体类型

——名称：Publish. Medium
——长名：媒体类型
——定义：语料发布的媒体类别。
——注释：
——值域：可为报纸、教材、一般图书、光盘、网络等。
——类型：基本元素
——来源：自定义元数据
——备注：

4.3.2　发行范围类型

——名称：Publish. Type
——长名：发行范围类型
——定义：语料原作的发行范围类型。
——注释：可参照报纸的发行范围取值：中央、地方、专业。
——值域：
——类型：基本元素
——来源：自定义元数据

——备注：

4.3.3　发行范围

——名称：Publish. Area

——长名：发行范围

——定义：指出版物的具体发行范围。

——注释：

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.3.4　发行周期

——名称：Publish. Period

——长名：发行周期

——定义：指出版物的发行周期。

——注释：

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.3.5　印数

——名称：Publish. Amount

——长名：印数

——定义：指出版物的印数。

——注释：

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.4　语料的内容信息

4.4.1　语体

——名称：Mode

——长名：语体

——定义：依据不同风格特点划分出来的语言表达形式的类别。
——注释：
——值域：
——类型：基本元素
——来源：自定义元数据
——备注：

4.4.2　文体

——名称：Style
——长名：文体
——定义：文章的体裁。
——注释：文章的体裁主要针对书面语而言。
——值域：
——类型：基本元素
——来源：自定义元数据
——备注：

4.4.3　主题

——名称：Subject
——长名：主题
——定义：语料的主题描述信息。
——注释：应尽可能选取最专指的主题词进行标引，一般可标引学科主题。
——值域：
——类型：基本元素
——来源：DC 元数据
——备注：

4.4.4　内容描述

——名称：Description
——长名：内容描述
——定义：资源内容的描述。
——注释：可以摘要、表格、图或其他形式呈现。
——值域：
——类型：基本元素
——来源：DC 元数据
——备注：

4.4.5 语言

——名称：Language

——长名：语言

——定义：资源内容所使用的语言。

——注释：可使用 RFC1766 定义语言的规范：前两个字母是语言代码，遵循 ISO 639 规范；接下来的两个字母为可选项，由国家码（country code）组成，遵循 ISO 3166 规范。

——值域：

——类型：基本元素

——来源：DC 元数据

——备注：

4.4.6 关联性

——名称：Relation

——长名：关联性

——定义：描述此资源和其他资源的关系。

——注释：最好由正式的全球性识别系统认证的文字或数字组成。

——值域：

——类型：基本元素

——来源：DC 元数据

——备注：

4.5 语料的采集方式信息

4.5.1 样本采集

——名称：Sample

——长名：样本采集

——定义：关于语料样本采集的描述。

——注释：关于语料采样原则、方式和语料来源的说明，可为简单的文字说明，也可为包含这些信息的文件的名称。

——值域：

——类型：基本元素或者文件引用

——来源：自定义元数据

——备注：

4.5.2 样本抽取方式

——名称：Sample. Abstraction

——长名：样本抽取方式

——定义：从原文语料中抽取样本语料的方式。

——注释：从原文抽取语料样本时，可随机抽取原文的一部分，也可取全文，还可有其他一些方式。

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.5.3 样本位置

——名称：Sample. Position

——长名：样本位置

——定义：样本在原文中的位置

——注释：标明语料样本所在原文的位置（开头、中间或结尾），也可标明所在原文的起止页数。

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.5.4 样本长度

——名称：Sample. Length

——长名：样本长度

——定义：语料样本的字数

——注释：

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.5.5 谈话环境

——名称：Speech. Environment

——长名：谈话环境

——定义：指示谈话发生的主题环境。

——注释：谈话可为有主题、受控的，也可为无主题、随机的。

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.5.6 谈话事件

——名称：Speech. Event

——长名：谈话事件

——定义：指示谈话所属的主题事件。

——注释：谈话可在某个事件中发生的，如打电话、看病、演讲等。该元数据项和元数据项“Subject”有冗余，但该元数据项更侧重于口语语料的标注。

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.5.7 谈话地点

——名称：Speech. Place

——长名：谈话地点

——定义：指示谈话发生的地点。

——注释：谈话的地点可为家、办公室、公共场所、录音棚等。

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.6 语料的管理信息

4.6.1 编号

——名称：Identifier

——长名：编号

——定义：语料库中每条语料的唯一编号，用以标识和管理语料记录，由语料库管理人员按照一定的规则赋予语料记录。

——注释：本元数据项虽名称与 DC 元数据项一致，但定义与 DC 元数据略有

不同，DC 元数据定义中它是用来标识资源的字串或者数字。

——值域：

——类型：基本元素

——来源：DC 元数据

——备注：

4.6.2　录入方法

——名称：Input

——长名：录入方法

——定义：语料的录入方法。

——注释：语料的录入方法可为人工录入、扫描识别，也可直接来源于电子文本。

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.6.3　标注

——名称：Annotation

——长名：标注

——定义：关于语料标注的说明

——注释：说明语料的标注内容，可为简单说明，如分词、词性标注等，也可为关于标注信息的一个文件的名称。

——值域：

——类型：基本元素或者文件引用

——来源：自定义元数据

——备注：

4.6.4　标注方式

——名称：Annotation. Type

——长名：标注方式

——定义：语料的标注方式。

——注释：

——值域：语料的标注方式有人工标注、机器自动标注、机器标注加人工校对等方式。

——类型：基本元素

——来源：自定义元数据

——备注：

4.6.5 标注语料的权限

——名称：Annotation. Rights

——长名：标注语料的权限

——定义：加工后的语料的权限描述。

——注释：可为一个权限管理的陈述，也可为一个权限管理陈述的标识，或者是提供资源权限管理的服务器的标识。

——值域：

——类型：文件引用或基本元素

——来源：自定义元数据

——备注：

4.6.6 标注软件

——名称：Annotation. Software

——长名：标注软件

——定义：语料标注所用软件的说明。

——注释：给出软件名称以及所使用的版本。

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.6.7 标注时间

——名称：Annotation. Date

——长名：语料标注时间

——定义：语料标注的时间

——注释：建议使用 YYYY - MM - DD 格式。

——值域：

——类型：基本元素

——来源：自定义元数据

——备注：

4.6.8 格式

——名称：Format

——长名：格式

——定义：描述资源的数据格式。

——注释：

——值域：

——类型：基本元素

——来源：DC 元数据

——备注：

4.6.9　标记语言

——名称：Format. Markup

——长名：标记语言

——定义：描述电子资源采用的卷标语言

——注释：本元数据记录标注语料的模式文件名称，如 SGML DTD、XML Schema 等类型文件的名称。

——值域：

——类型：基本元素

——来源：OLAC 元数据

——备注：

4.6.10　处理器需求

——名称：Format. Cpu

——长名：处理器需求

——定义：运行语言资源软件时所需的 CPU 规格。

——注释：

——值域：

——类型：基本元素

——来源：OLAC 元数据

——备注：

4.6.11　操作系统需求

——名称：Format. Os

——长名：操作系统需求

——定义：执行软件资源时所需的操作系统环境。

——注释：

——值域：

——类型：基本元素

——来源：OLAC 元数据

——备注：

4.6.12　贡献者

——名称：Contributor

——长名：贡献者

——定义：任何对资源内容有贡献的个人、组织或服务中心的信息。

——注释：

——值域：

——类型：基本元素

——来源：DC 元数据

——备注：

《现代汉语语料库元数据规范（草案）》研制报告

一　研制背景

（一）必要性

元数据（Metadata）可泛义地理解为关于数据的数据或关于数据的信息。语料库研究中早就有了元数据的描述，一般称作语料的篇头信息。

元数据对于语料库语言学研究具有重要意义，它可以记录语料的时间、地域、作者、文体、知识版权、加工、管理等信息；也可以通过它形成不同的子语料库，满足研究者的不同研究需要。

目前，汉语语料库的元数据设计还没有统一的标准。语料库建设时，设计者一般是根据个人经验设计与标注元数据项，且往往只考虑了当时的应用需求。但是，当以后需要将该语料库用于其它研究时，则可能因元数据不全，影响语料库的进一步研究与应用。

由于没有统一的语料库元数据规范，还使得元数据描述格式与命名标准不统一，使得语料库的共享、数据交换、语料库之间的比较研究受到限制，为网络环境下的语料库集成和应用软件开发带来困难。因此迫切需要制定语料库元数据规范，实现语料库的文本描述规范化，提高语料库建设的质量和效率，提高语料库的共享性、重用性和利用率。

（二）意义和作用

现代汉语语料库元数据规范（草案）（以下简称语料库元数据规范（草案））对于基于语料库的语言学研究、语言教学、自然语言处理研究都有重要意义，其主要作用如下：

1. 语料库元数据规范（草案）定义了一套较为完备的元数据集合。本规范

（草案）在分析、总结国家语委现代汉语语料库、BNC 语料库、台湾 Sinica 语料库等国内外一些大型语料库的元数据的基础上，定义了一个较为完备的核心元数据集。

2. 语料库元数据规范（草案）定义了统一的元数据描述格式。本规范（草案）较严格地定义了每个元数据的语义、描述格式，避免了元数据语义上的模糊性、格式上的不统一。

3. 语料库元数据规范（草案）可以一定程度上解决元数据命名规则不统一所导致的语料共享困难。当前，语料库的元数据命名不统一的现象表现为两种形式：一是“同义不同名”，如“学科”“主题”往往指同样的数据；二是“同名不同义”，如“日期”，有些是指出版日期，有些是指写作日期。本规范（草案）提供了一套统一的命名规则，有利于语料库资源共享、数据交换以及语料库之间的比较研究。

4. 语料库元数据规范（草案）与国际通用标准具有较好的兼容性。本规范（草案）引入了国际文献领域推行的 DC 元数据标准、开放语言资源组织的 OLAC 元数据标准，与国际通用的标准能够较好地兼容。

5. 语料库元数据规范（草案）中定义的元数据集具有较完备的描述能力。本规范（草案）的元数据集中的 43 个元数据从 6 个方面对语料库及语料本身的信息进行了较详细的描述。

（三）立项

国家语言文字应用“十五”重点项目——“文本描述的语言规范及语料库选材研究”，由国家语委 2002 年 12 月批准立项，华中师范大学承担。语料库元数据规范（草案）是该项目的主要研究成果之一。

二　研制过程

（一）研制和征求意见

语料库元数据规范（草案）的研制过程如下：

1. 广泛研究汉语和其他语言的各种语料库，归纳、整理语料库的文本描述格式和相关的元数据项，调查语言学研究、自然语言处理研究对语料库的需求，借鉴文献领域的经验，归纳出语料库文本描述所需要的通用元数据。

2. 参考国际上相关的一些电子资源的元数据规范，结合语料库实际，制定现

代汉语语料库元数据集合，定义元数据项共同的属性集合。

3. 就规范草案征求有关专家意见，根据意见进行反复修改和完善。

（二）鉴定

2005 年 1 月 17 日，教育部语言文字信息管理司委托中国科学院声学研究所组织鉴定通过了“文本描述的语言规范及语料库选材研究”项目的成果。鉴定专家认为本规范（草案）的成果有利于提高语料库建设的效率和质量、实现语料库的共享和集成、提高语料库的重用性。

鉴定组组长为周锡令先生，成员有冯志伟、张普、曹右琦、鲁川、詹卫东等 6 位专家。

三　研制原则和基本依据

（一）研制原则

语料库元数据规范（草案）的研制原则主要包括以下 3 点：

1. 面向普通用户，格式、规则简单明了。本规范（草案）的用户对象主要是语料库的开发人员或使用人员，大多数都不是专业的文献著录人员，不可能花很多精力去学习和掌握复杂的标注格式，因此，语料库的元数据格式要尽量接近日常的语言习惯。

2. 兼容 DC 元数据、OLAC 元数据。DC 元数据集合中的 15 个元数据全部包含在本规范的元数据集合中；OLAC 元数据集合主要采用 DC 元数据，又进行了一些扩展，其中的 18 个元数据包含在本规范的元数据集合中。这些信息分别在每个元数据项的来源属性上标记。

3. 语料库元数据规范（草案）设计时既要考虑信息的全面性，又要考虑用户的个性化需求。语料库元数据规范（草案）定义了常用的数据项，在具体标注时，设计人员在遵守规范约定的前提下可以选择其中的一些项目，同时还可再增加一些别的项目。

（二）基本依据

研制语料库元数据规范（草案）主要参考以下规范和语料库：

1. DC 元数据（见附录 A）DC 元数据是国际文献管理领域的元数据标准，主要用于管理网络上巨大的信息资源，与图书馆常用的 MARC 格式相比，其特点是简单明了、有弹性、面向用户、机器可读。它的一些特点和语料库的元数据有共

同之处，这是语料库元数据规范中值得借鉴的标准之一。

2. OLAC 元数据标准（见附录 B）　通过互联网建设全球范围内的虚拟语言资源图书馆。访问其主页，就可以看到它的元数据规范标准，这个标准是该联盟最重要的标准文件之一。它基本采用 DC 元数据，并允许增加扩展的元数据。

3. 国际、国内一些大型语料库的元数据　为了更好地定义语料库元数据集，课题组详细地分析了不同类型的语料库的元数据，这些语料库包括 BNC 语料库、台湾现代汉语平衡语料库、国家语委现代汉语平衡语料库等。

四　研制内容

（一）元数据集

语料库元数据规范（草案）在兼容 DC 以及 OLAC 元数据标准的前提下，定义了适合于现代汉语语料库的 43 个核心元数据，分成以下 6 个类别（见下表）：

1. 语料的知识产权信息　主要包括原始语料的创作、出版、发行等方面的信息。

2. 语料创建者的背景信息　包括创建者的性别、年龄、母语、籍贯等信息。

3. 语料载体的发行信息　包括发布语料的媒体类型、发行范围、发行周期、发行量等，这些数据可以提供语料的覆盖范围、影响面、流通度等信息，是评价、比较语料库的平衡度与代表性的重要的参考数据；同时，由于不同载体的语言风格有不同的特点，记录下这些数据，对语言学研究也具有参考价值。

4. 语料的内容信息　描述语料本身的语言学特征、文学特征、内容特征等。

5. 语料的采集方式信息　包括样本抽取方式、样本位置、样本字数、谈话环境、谈话事件和地点等。

6. 语料的管理信息　主要记录语料库的标注方式、加工后的语料的知识产权、应用环境等信息。

语料库元数据规范（草案）定义的元数据集合

语料的知识产权信息	语料创建者的背景信息	语料载体的发行信息	语料的内容信息	语料的采集方式信息	语料的管理信息
Title 标题	Creator 创建者	Publish. Medium 媒体类型	Mode 语体	Sample 样本采集	Identifier 编号
Source 语料来源	Creator. Type 创建者形式	Publish. Type 发行范围类型	Style 文体	Sample. Abstraction 样本抽取方式	Input 录入方法

续表

语料的知识产权信息	语料创建者的背景信息	语料载体的发行信息	语料的内容信息	语料的采集方式信息	语料的管理信息
Issued_Date 出版时间	Creator. Native _Place 创建者籍贯	Publish. Period 发行周期	Description 内容描述	Sample. length 样本长度	Annotation. Type 标注方式
Created_Date 创作时间	Creator. Sex 创建者性别	Publish. Area 发行范围	Subject 主题	Sample. Position 样本位置	Annotation 标注
Source_Rights 原作权限	Creator. Native _ Language 创建者母语	Publish. Amount 印数	Language 语言	Speech. Environment 谈话环境	Annotation. Rights 标注语料的权限
Type 原作类型	Creator. Age 创建者年龄		Relation 关联性	Speech. Event 谈话事件	Annotation. Software 标注软件
Coverage 覆盖范围				Speech. Place 谈话地点	Annotation. Date 语料标注时间
					Format 格式
					Format. Markup 标记语言
					Format. Cpu 处理器需求
					Format. Os 操作系统需求
					Contributor 贡献者

（二）元数据描述格式

语料库元数据规范（草案）设计了元数据的描述格式，定义了元数据的8个属性：名称（Name）、长名（Full Title）、定义（Definition）、注释（Comments）、值域（Value Land）、类型（Type）、来源（Defined_In）、备注（Remark）。这些属性的解释参看现代汉语语料库元数据规范（草案）。

五　与相关标准的关系

语料库元数据规范（草案）中保留了 DC 元数据核心元素集的全部 15 个数据项及其英文名称，并在这些元数据的“来源”属性上标注了“DC 元数据”，实现了对 DC 元数据标准的兼容。

OLAC 元数据集（标准集）的元数据项共有 23 个，它在包含 DC 元数据的全部 15 个元素之外另增加了 8 个元素。语料库元数据规范（草案）包含了这新增的 8 个元素中的 3 个元素，并在这些元数据的“来源”属性上标注了“OLAC 元数据”，实现了对 OLAC 元数据标准的部分兼容。

语料库元数据规范（草案）共定义了 43 个元数据，其中 15 个来源于 DC 元数据，3 个来源于 OLAC 元数据，自定义的元数据有 25 个。自定义的元数据主要是语料库建设特有的一些数据项。

六　相关资料

（一）参考文献

[1] DCMI Metadata Terms. http：//dublincore. org/documents/dcmi - terms/
[2] OLAC Metadata. http：//www. language - archives. org/OLAC/metadata. html
[3] What is the BNC. http：//www. hcu. ox. ac. uk/BNC/what/index. html
[4] 吴健中《DC 元数据》，上海：上海科学技术文献出版社，2000 年
[5] 庄育飞，郑卫，Dublin Core，《网络资源组织与整理的新思路 》，《情报学报》2000，19（4）
[6] 房庆，《浅议信息化与元数据标准》，《术语标准化与信息技术》2002，25（1）
[7] 邢福义，《现代汉语》，北京：高等教育出版社，1991
[8] 何婷婷，沈辉宇，《语料库文本描述的语言规范》，《语言文字应用》2005 第 4 期

（二）参加工作的单位和人员

研制单位：华中师范大学
研制负责人：何婷婷
主要研制人：沈辉宇　徐晓琦

本课题研制过程中，教育部语言文字信息管理司李宇明教授给予了全面、具

体的指导，提出了许多建设性的意见，OLAC 执行委员、香港理工大学台湾语言研究所黄居仁先生推荐了 OLAC 标准，中国科学院声学研究所张全教授提出了许多具体的修改意见，在此表示最诚挚的感谢。

现代汉语语料库元数据规范（草案）课题组
2008 年 7 月 30 日

附录 A　DC 元素集

DC 元素集是元数据中的一个标准集—都柏林核心元素集（Dublin Core Element Set），简称为都柏林核心（即 DC）。DC 元数据指都柏林核心元数据（Dublin Core Metadata），是一种跨领域的信息资源描述标准。DC 分为简单 DC 和复杂 DC，简单 DC 指的是 DC 的 15 个核心元素，它们可以分为 3 类。

资源内容描述类	知识产权描述类	外部属性描述类
Title	Creator	Date
Subject	Publisher	Type
Description	Contributor	Format
Language	Rights	Identifier
Source		
Relation		
Coverage		

附录 B　OLAC 元数据集

OLAC（Open Language Archives Community）是一个国际合作组织，它通过互联网建设全球范围内的虚拟语言资源图书馆，OLAC 元数据集指该组织定义的元数据。OLAC 元数据规范标准（http：//www. language - archives. org/）基本采用 DC 元数据，并允许增加扩展的元数据。OLAC 元数据集（标准集）共有 23 个元数据项，分为 3 类（如表 3 所示）。OLAC 元数据集（标准集）中包含了 DC 元素集

的全部15个元素，并新增加了8个元素，这8个元素在表中用斜体标识。

资源内容描述类	知识产权描述类	外部属性描述类
Title	Creator	Date
Coverage	Publisher	Identifier
Description	Contributor	Format
Language	Rights	*Format. cpu*
Source		*Format. markup*
Relation		*Format. os*
Subject		*Format. sourcecode*
Subject. language		*Format. encoding*
		Type
		Type. data
		Type. function