语料库系统语言文字评测规范（草案）

1 范围

本规范（草案）提出了语料库系统的评测的一般原则和具体方法。

本规范（草案）可供语料库系统评测参考使用。

2 规范性引用文件

ISO11179－3 信息技术 数据元的规范与标准化 第3部分：数据元的基本属性

GB/T12200.1 汉语信息处理词汇01部分：基本术语

GB/T13725 信息处理用现代汉语分词规范

GB3259－92 中文书刊名称汉语拼音拼写法

GB/T16785－1997 术语工作 概念与术语的协调

GB/T16786－1997 术语工作 计算机应用 数据类目

GB/T17532－1998 术语工作 计算机应用 词汇

GB/T15834－1995 标点符号用法

GB/T15835－1995 出版物上数字用法的规定

GB/T16159－1996 汉语拼音正词法基本规则

第一批异形词整理表

第一批异体字整理表

部分计量单位名称统一用字表

中国人名汉语拼音字母拼写法

中国地名汉语拼音字母拼写规则

普通话异读词审音表

文语转换和语音识别系统语言文字评测规范（草案）

现代汉语语料库元数据规范（草案）

3 术语和定义

下列术语和定义适用于本规范（草案）。

3.1 语料库

为一个或多个应用目标而专门收集的、有一定结构的、有代表性的、可被计算机程序检索的、具有一定规模的语料的集合。

3.2 元数据

关于数据的数据，是描述语言资源特征的结构化数据。

4 语料库系统评测的一般原则和方法

4.1 评测原则

本规范（草案）参照使用《文语转换与语音识别系统评测规范（草案）》中规定的自然语言信息处理系统评测的一般原则和方法。

4.2 评测方法

语料库系统评测基本上只涉及系统外在的总体性能，主要采用黑箱评测的方法。

5 语料库的类型

a. 按语料选取的时间划分，可分为历时语料库和共时语料库。
b. 按语料库的结构划分，可分为平衡结构语料库和自然随机结构的语料库。
c. 按语料库的用途划分，可分为通用语料库和专用语料库。
d. 按语料库的表达形式划分，可分为口语语料库和文本语料库。
e. 按语料库中语料的语种划分，可分为单语种语料库和多语种语料库。
f. 按语料库的动态更新程度划分，可分为参考语料库和监控语料库。

6 语料库内容的评测

6.1 语料库代表性的评测

a. 有限的样本语料应尽可能多地反映无限的真实语言现象的特征。样本不仅取自于符合语言文字规范的真实的语言材料，且样本要来源于正在“使用中”的语言材料，包括各种环境下的、规范的或非规范的语言应用。

b. 看语料的样本应能反映语言的发展变化，应能反映当代的语言生活规律的语料。

c. 语料库评测时，还应指出语料库中存在的那些不规范但被广泛接受的语言现象、以及包含有若干错误的语言现象，以反映语言文字使用的真实面貌。

6.2 语料库规范性的评测

a. 语料应符合国家有关语言文字的规范。如国家关于异体字、异形词、简化字、数字用法、标点符号用法、计量单位名称、异读词的规范。

b. 应根据《第一批异体字整理表》《第一批异形词整理表》《部分计量单位名称统一用字表》《简化字总表》《GB/T15834—1995 标点符号用法》《GB/T15835—1995 出版物上数字用法的规定》《汉语拼音方案》《中国人名汉语拼音字母拼写法》《普通话异读词审音表》《中文书刊名称汉语拼音拼写法》等语言文字规范标准，设置相应的测试点，对语料库中的语言文字进行检查，以评测语料库符合规范的程度。如设置如下的测试点来测试语料库中异体字、异形词的规范性：

·异体字：汉语书面语中并存并用的同音、同义而书写形式不同的字，如：“雇—僱”。应根据《第一批异体字整理表》测试其规范性，以“雇”为规范字。

·异形词：汉语书面语中并存并用的同音、同义而书写形式不同的词语，如“按语—案语”“百废俱兴—百废具兴”，应根据《第一批异形词整理表》测试其规范性，以“按语”“百废俱兴”为规范词语。

c. 语料库中的不规范的语言现象，应根据国家有关规范进行测试，以评测语料库规范的程度；但对于某些特殊用途的语料库，如外国留学生汉语学习中介语语料库，就以语料的真实性为主，而不强求对其进行规范。

6.3 语料库结构性的评测

a. 语料库须是以电子文本形式存在的、计算机可读的语料集合。

b. 语料库的逻辑结构设计要确定语料库子库的组成情况，定义语料库中语料记录的码、元数据项、每个数据项的数据类型、数据宽度、取值范围、完整性约束等。

c. 在语料库建设中，提倡采用通用的扩展标记语言 XML（eXtensible Markup Language）来组织语料文件；使用 XML 语言组织语料库时，一个语料库的文件是一个或多个 XML 格式的文件集合，建议采用 DTD（Document Type Definition，文件类型定义）或者 XML 模式（XML SCHEMA）来定义它们的结构；语料文件的形式可是纯文本文件、XML 格式的文本文件、关系数据库文件等。

6.4 语料库平衡性的评测

a. 在平衡语料库中，语料库为了达到平衡，首先要确定语料的平衡因子，平衡因子是影响语料库代表性的关键特征。

b. 影响语言应用的因素很多，如，学科、年代、文体、地域、登载语料的媒体、使用者的年龄、性别、文化背景、阅历、语料的用途（公函、私信、广告）等等。通常根据实际需要选取一个或者几个重要的指标作为平衡因子。最常用的平衡因子有学科、年代、文体、地域等。应根据平衡语料库的用途来评测语料库所选择的平衡因子的恰当性。

6.5 语料库规模的评测

大规模的语料库对于语言研究，特别是自然语言处理研究具有不可替代的作用。当语料库达到一定的规模后，语料库的功能并不会随着其规模同步地增长，语料库规模的大小应以是否能够满足其需要来决定。应根据实际的需要来评测语料库的规模。

7 语料库元数据的评测

语料的元数据对语料库语言学研究具有重要的意义，可通过元数据了解语料的时间信息、地域信息、作者信息、文体信息等各种相关信息；也可通过元数据

形成不同的子语料库，满足不同兴趣研究者的研究需要；还可通过元数据对不同的子语料库进行比较，研究和发现一些对语言应用和语言发展可能有影响的因素；元数据还可记录语料的知识版权信息，记录语料库的加工信息和管理信息。

7.1 语料库元数据评测的原则

7.1.1 简单明了、面向用户

语料库的元数据要尽量接近日常的语言习惯，满足一般用户的要求。

7.1.2 有弹性、可扩展

语料库的篇头标注信息除语料的知识版权信息、语料创建者的背景信息、语料载体的发行信息、语料的内容信息、语料的采样方式信息（书面语料或者口头语料）、语料的管理信息等共同项外，不同的语料库还有其各自特殊的要求，语料库元数据的标准需要定义共同的数据项、命名规则、数据类型、数据宽度。在具体标注时，设计人员可选择其中的一些项目，这些项目要遵守规范的约定，设计人员还可另外再增加一些别的项目。

7.1.3 用标准的英文单词定义元数据项名

有些软件在解读数据时不支持中文的变量名，元数据项命名时，最好用西文符号。另外，应尽量用标准的英文单词定义元数据项名，而不要使用汉语拼音的简写，以便国际交流。

7.1.4 机器可读

标注后的语料库的元数据要能被通用的计算机程序解读，而不应专门编写程序来解读，这是实现语料库可共享、可集成的关键。用目前流行的文本标记语言XML来标注语料，可部分达到这个目标。

7.1.5 遵守元数据的国际标准

语料库元数据规范的制定应遵守元数据定义的国家标准和国际标准。提倡使用国际通用的XML语言来组织语料库中的语料。

7.2 元数据的国际标准 DC

国际通用的DC（Dublin Core）元数据是国际文献管理领域推行的一个元数据标准，主要用于管理网络信息资源。DC数据元格式是在1995年3月由OCLC的NCSA（National Center for Supercomputer Application）联合召开的第一次专题研讨会上产生的，其目的在于研制一套简洁的、有弹性的、非专业人员也可掌握和使

用的信息资源著录格式，以提高网络信息资源的开发利用效率。DC 数据元已被开放语言文档联盟 OLAC（the Open Language Archives Community）采用，OLAC 采用的 DC 元数据包括 15 个著录项，分为 3 类。

7.2.1 资源内容描述类元数据

a. 标题项（title）：由资源创建者或者出版者给定的资源名称。

b. 主题项（subject）：表示资源对象主题内容或者学科内容的关键词。

c. 描述项（description）：资源内容的文本描述，包括文献类对象的文摘或者视觉作品的内容描述。

d. 语言项（language）：资源对象所用的语言。

e. 来源项（source）：当前资源或者二次资源的来源，如：创建日期、创建者、形式、标识等。

f. 关联项（relation）：二次资源与当前资源的关联关系。如：从 XX 再编目、翻译自 XX、节选自 XX、格式转换自 XX 等。

g. 覆盖范围项（coverage）：资源知识内容的时空特征。

7.2.2 知识产权描述类元数据

a. 创建者项（creator）：创建资源知识内容的主要负责人或机构。

b. 出版者项（publisher）：使资源成为当前形态的责任者，如出版社、大学、公司等。

c. 合作者项（contributer）：在著者项中没有列出的对于资源有贡献的其他个人或组织，或者贡献仅次于创建者的合作者（如，编辑、誊写员、美工人员）。

d. 权限项（rights）：关于权限管理的陈述。

7.2.3 外部属性描述类元数据

a. 日期项（date）：与创建资源使之成为可利用状态的相关日期。

b. 类型项（type）：资源的类型，如小说、诗歌、散文、论文、词典等。

c. 识别符（identifier）：惟一地标识资源的字符串或数字，如 URL，ISBN 等。

d. 格式项（format）：资源的数据格式，如文本格式、JPEG 图像等。

7.3 制定语料库元数据的原则

语料库元数据的制定应遵循如下原则：

a. 标准化原则；语料库元数据应遵守元数据定义的国际标准和国家标准。

b. 简易性原则：语料库元数据应简单明了，便于一般用户掌握和使用。

c. 灵活性原则：除了须遵守的元数据规范之外，还可针对不同语料库的特点，

增加相应的元数据。

d. 罗马化原则：元数据的命名，最好采用单一的罗马字母，使用罗马字母来表示元数据的“名称”，以便计算机软件识别和国际交流，简写最好不要根据汉语拼音而根据英文单词。罗马化的名称作为保存信息时使用。这样的元数据名称应有中文名称作为“长名”，在显示信息时使用。

e. 机器可读原则：语料库的元数据应可由通用的计算机程序解读，而不需要专门的程序来解读。可采用 XML 语言来标注语料库的格式。

7.4 语料库元数据集合的内容

语料库元数据集合的内容包括 6 大类：

a. 知识版权信息
- Title（标题）
- Source Identifier（语料来源）
- Created Date（制作时间）
- Issued Date（出版时间）
- Copyright（原作版权）
- Resource Type（载体形式）

b. 语料创建者的背景信息
- Agent Type（创建者形式）
- Creator（创建者）
- Sex（性别）
- Birth Place（籍贯）
- Mother Language（母语）
- Age（年龄）
- Contributor（贡献者）

c. 语料载体的发行性质
- Medium Type（媒体类型）
- Publication Type（发行类型）
- Publication Area（发行范围）
- Publication Period（发行周期）
- Publication Amount（发行量）

d. 语料的内容信息

— Genre（语体）
— Style（文体）
— Subject（主题）
— Description（内容描述）
— Language（语言）
— Markup Language（标记语言）
— Relation（关联性）
— Source（来源）

e. 语料采集方式信息
— Extraction Type（样本抽取方式）
— Sample Position（样本位置）
— Characters Amount of Resource（原文字数）
— Characters Amount of Sample（样本字数）
— Environment（采集环境）
— Event（事件）
— Place（采集地点）

f. 语料的管理信息
— Identifier（编号）
— Sample Name（语料标题）
— Input Type（录入方法）
— Annotation Type（标注方式）
— Modified Date（更新时间）
— Copyright after Annotation（所属单位）
— Description of Copyright（许可权说明）
— Limitation（许可范围）
— Software（标注软件）
— Created Date（创建时间）
— Format（资源格式）
— Format. cpu（处理器）
— Format. os（操作系统）

8 语料库加工技术的评测

语料库的加工技术包括语料库自动切词技术、自动标注技术和树库的构建技

术。本规范（草案）只评测语料库的自动切词和自动标注技术。语料库的自动切词就是使用计算机把连续汉字文本中的单词切出来，使单词与单词之间出现空白。语料库的自动标注就是使用计算机给切分后的各个单元标注上正确的词类和其他语法、语义信息。

8.1 语料库自动切词和自动标注评测的原则

a. 语料库的自动切词的评测应遵循国家标准《GB/T13715 信息处理用现代汉语分词规范》（以下简称《分词规范》）。

b. 对具体词语的切分，在考虑规范仍然举棋不定的情况下，可参照得到广大用户认可的《现代汉语词典》来决定。例如，“立功/的/机会/有的是/。”中的“有的是”在《分词规范》中没有规定，但在《现代汉语词典》中收录了，就可将“有的是”作为一个切词单位。

c. 不同的应用对象对于切词颗粒度的要求不完全相同，为了兼容不同词语的颗粒度，可容许同一语言结构按照不同的层次切分。例如，“工具箱”可切分为“工具”+“箱”，也可算为一个切分单位“工具箱”，这时，可使用多层次的括号式表示为［工具/n 箱/n］n（其中 n 为名词）。

d. 应注意切分时的歧义。切分歧义主要表现为：

——交集型歧义切分字段：如“从小学”在“从小学电脑”中应切分为“从小/学”，在“从小学毕业后”中应切分为“从/小学”。

——多义组合型歧义切分字段：如“将来”在“他将来北京工作”中应分别切分为“将”和“来”，在“情况将来会改变”中不能切分，应视为一个单词“将来”。

e. 应注意命名实体（人名、地名、机构名）的正确切分。大多数的命名实体都不会存储在机器词典中，切分时容易出现错误，应把命名实体的切分作为语料库自动切词评测的重要内容。

f. 标注时应注意区分兼类词，选择正确的词性标注。

如，路很直（“直”应标注为 a）

他直哭（“直”应标注为 d）

又如，我在家（“在”应标注为 v）

我在办公室开会（“在”应标注为 p）

再如，他从日本回来（“从”应标注为 p）

我从不抽烟（“从”应标注为 d）

g. 根据上述原则，采用手工或者半自动的方法制定评测语料自动切词和自动标注的标准答案。

下面是国家语委现代汉语语料库切词和标注语料的样例，可作为评测时的标准答案：

鸟/n 的/u 世界/n

杨栋/nh

鸟/n 是/vl［大/a 自然/n］n 的/u 歌手/n，/w 鸟语/n［就/d 是/vl］vl［大/a 自然/n］n 的/u 音乐/n 和/c 诗歌/n 了/u。/w

山村/n 里/nd 的/u 鸟/n 除了/p 麻雀/n，/w 就/d 数/v 燕子/n 多/a 了/u。/w［村/n 人/n］n 对/p 燕子/n 很/d 爱护/v，/w 说/v 它/r 吃/v 庄稼/n 的/u 害虫/n，/w 常/a 吓唬/v［孩子/n 们/k］n 不要/vu 去/v 玩/v 燕子/n，/w 会/vu 坏/v 自己/r 的/u 眼睛/n。/w 有时/r 光/a 屁股/n 的/u 小/a 燕/n 掉/v 下来/vd，/w 也/d 要/vu 送回/v［燕/n 窝/n］n 里/nd 去/vd。/w

词类标记说明：

n—名词，nh—人名，u—助词，vl—系动词，w—标点符号，d—副词，c—连接词，nd—方位词，p—介词，a—形容词，r—代词，k—后加成分，vu—助动词，vd—趋向动词。

8.2 语料库自动切词和自动标注评测中的若干定义

语料库的自动切词和自动标注的评测在很大的程度上依赖于词典，由于参测语料库系统的词典中的词条和词的颗粒度不完全相同，有必要明确给出有关定义。

8.2.1 正确切词和错误切词

如果切词序列 $S_iS_{i+1}\cdots S_j$ 中的汉字序列与切词序列 $S_{i1}S_{i1+1}\cdots S_{j1}$ 中的汉字序列一致，则称切词序列 $S_iS_{i+1}\cdots S_j$ 与切词序列 $S_{i1}S_{i1+1}\cdots S_{j1}$ 相等，记为 $S_iS_{i+1}\cdots S_j = S_{i1}S_{i1+1}\cdots S_{j1}$。例如，工具/n 箱/n = 工具箱/n。

在给定的语料中，设其字符串的基本汉字序列为 $W_1W_2\cdots W_n$，如果在标准答案中存在切词序列 $S_iS_{i+1}\cdots S_{i+k}$，使得

$$X = S_iS_{i+1}\cdots S_{i+k},$$

则称 $X = W_1W_2\cdots W_n$ 为被测语料库系统的一个正确切词。这时，X 的正确切词数为 $k+1$。

例如，“工具/n 箱/n”是一个正确切词，正确切词数为 2；“工具箱/n”也是一个正确切词，正确切词数为 1。

不正确的切词，称为错误切词。

8.2.2　正确标注和错误标注

对被测语料库系统的正确切词 X，X 的词性标注是 T，标准切词 S_{i1}，S_{i1+1}，…，S_{i1+k} 的词性标注依次是 T_0，T_1，…，T_k，若 T 与 T_0，T_1，…，T_k 一一匹配，则 X 的标注为正确标注，且正确标注数为 k + 1，由于正确标注之前须正确切词，所以，这个 k + 1 也可称为正确标注切词数；若 T 与 T_0，T_1，…，T_k 不完全匹配，则不匹配的标注为错误标注，不匹配的标注数就是错误标注数。在通常情况下，切词的颗粒度越大，其词性标注的歧义越小。当存在兼类词的情况下，应进行兼类词判断，从若干个标注中选择出一个正确的标注。

8.3　切词和标注结果的计算方法

8.3.1　切词正确率（SR）

$$SR = \frac{SRN}{Sum}$$

注：SRN 是被测语料中正确切词数，Sum 是与被测语料对比的标准切词中切词的总数。

8.3.2　词性标注正确率（TR）

$$TR = \frac{TRN}{Sum}$$

注：其中，TRN 是被测语料中正确标注切词数，Sum 是与被测语料对比的标准切词中切词的总数。由于切词错误时标注就没有意义了，TRN 是指被测语料中切词和标注都正确的数目，所以，总是有 TRN≤SRN。

8.3.3　词性标注相对正确率（RR）

$$RR = \frac{TRN}{SRN}$$

注：TRN 是被测语料中正确标注切词数，SRN 是标准切词中正确切词数。

基于同一标准语料测试的结果具有可比性。在上述定义中，Sum 是标准语料的切词总数，SRN 和 TRN 都是参照标准语料的切词得到的，被测试语料的正确切词越多，SRN 就越大，SR 也就越大。同理，TRN，TR，RR 也是如此。

如：

鸟/n 的/u 世界/n

杨栋/nh

鸟/n 是/vl 大自然/n 的/u 歌手/n，/w 鸟语/n 就/d 是/vl 大自然/n 的/u 音乐/n 和/c 诗歌/n 了/u。/w

山村/n 里/nd 的/u 鸟/n 除了/p 麻雀/n，/w 就/d 数/v 燕子/n 多/a 了/u。/w 村人/n 对/p 燕子/n 很/d 爱护/v，/w 说/v 它/r 吃/v 庄稼/n 的/u 害虫/n，/w 常/a 吓唬/v 孩子/n 们/k 不要/vu 去/v 玩/v 燕子/n，/w 会/vu 坏/v 自己/r 的/u 眼睛/n。/w 有时/r 光/n 屁股/n 的/u 小/a 燕/n 掉/v 下来/vd，/w 也/d 要/vu 送回/v 燕/n 窝里/n 去/vd。/w

与标准答案相比，标准答案中的“大自然”切为“［大/a 自然/n］n”，被测语料切为“大自然/n”，是正确的切分；标准答案中的“就是”切为“［就/d 是/vl］vl”，被测语料切为“就/d 是/vl”，是正确切分；标准答案中的“村人”切为“［村/n 人/n］n”，被测语料切为“村人/n”，是正确切分；标准答案中的“孩子们”切为“［孩子/n 们/k］n”，被测语料切为“孩子/n 们/k”，是正确切分；标准答案中的“燕窝里”切为“燕窝/n 里/nd”，被测语料库切为“燕/n 窝里/n”，是错误切分，因为这样的错误切分涉及到两个单词，算为 2 个错误切分。在被测语料中总共有 77 个切分单位，故 Sum = 77，有 2 个错误切分，故正确切词数为 75，SRN = 75，所以，

$$SR = \frac{SRN}{Sum} = \frac{75}{77} = 0.9740 = 97.40\%$$

与标准答案相比，标准答案中的“光”是名词和形容词兼类词，标准答案标注为 a，而被测语料标注为 n，是错误标注；如存在切词错误，标注也就没有价值了，故切词错误数也应被包含在标注错误数之内。在这种情况下，被测语料的错误标注数为 3，正确标注切词数为 74，故 TRN = 74。

$$TR = \frac{TRN}{Sum} = \frac{74}{77} = 0.9610 = 96.10\%$$

与标准答案相比，TRN = 74，SRN = 75。

$$RR = \frac{TRN}{SRN} = \frac{74}{75} = 0.9866 = 98.66\%$$